最优化理论与方法
Optimization Theory and Methods

无约束可微优化问题的**最优性条件**
Optimality Condition

- 最优化问题解的存在性
- 一阶必要条件
- 二阶必要条件
- 二阶充分条件
- 无约束可微凸优化的充要条件
- 例：线性最小二乘

最优化问题解的存在性

优化问题：$\min\limits_{x\in\mathbb{R}^n} \quad f(x)$ 其中 $\mathcal{X} \subseteq \mathbb{R}^n$ 为可行域。

$\text{s.t.} \quad x \in \mathcal{X}$

Weierstrass定理 定义在紧集上的连续函数一定存在最大（最小）值点。

(充分存在条件) 设 $f: R^n \to R$ 为定义在 R^n 上的连续函数， f 存在一个紧下水平集，则在 R^n 上存在 f 的一个全局极小值点。

在许多实际问题中，定义域可能不是紧的。但是如果函数本身具有某种性质时，在非紧集上也能取到全局最优解。

强制函数：一个适当且闭的函数 $f: \mathcal{X} \to (-\infty, +\infty]$ 是强制的(coercive)，对于任一满足 $\|x^k\| \to +\infty$ 的点列 $\{x^k\} \subset \mathcal{X}$ ，都有 $\lim\limits_{k\to\infty} f(x^k) = +\infty$，即所有下水平集都是紧集。

例 $\boldsymbol{x} \in \mathbb{R}^2, f(\boldsymbol{x}) = x_1^2 + x_2^2$ 是coercive

$\boldsymbol{x} \in \mathbb{R}^2, f(\boldsymbol{x}) = x_1^2 + x_2^2 - 2x_1x_2 = (x_1 - x_2)^2$ 不是coercive

$x \in \mathbb{R}, f(x) = 1 - e^{-|x|}$不是coercive

定理 设 $f:\mathbb{R}^n \to \mathbb{R}$ 为连续且强制的函数，则在 R^n 上存在 f 的全局最小点或者$S \subseteq \mathbb{R}^n$ 为非空闭集, 则 f 在 S 上有一个全局最小值点。

证明：设 $\mathbf{x}_0$ 是集合 S 中的任意一点，f 是强制函数，一定存在 $M > 0$ 使得对任意 $\|\mathbf{x}\| > M$ 满足 $f(\mathbf{x}) > f(\mathbf{x}_0)$ (*)

f 在 S 上的任意最小值点 $\mathbf{x}^*$ 满足 $f(\mathbf{x}^*) \le f(\mathbf{x}_0)$，由 $(*)$ 式可得，f 在 S 上的全局最小值点和 f 在 $S \cap B[0,M]$ 上的全局最小值点一样。

$S \cap B[0,M]$ 是紧集 $B[0,M]$ 的闭子集，因此 $S \cap B[0,M]$ 是紧集，且非空（通过调整 M 的大小），由Weierstrass定理可得，f 在 $S \cap B[0,M]$ 上存在全局最小值点，因此在 S 上也存在全局最小值点. □

例：$f(x) = x^2, x \in \mathcal{X} = \mathbb{R}$，定义域不是紧集，不能直接利用Weierstrass定理。但x^2是强制函数，其全局最优解一定存在。

适当且闭的函数 $f(x) = e^{-x}, x \in \mathcal{X} = \mathbb{R}$，不是强制函数，因此不能断言其全局极小值点存在。事实上，其全局极小值点不存在。

定理(强凸函数是强制函数) 设 $f:\mathbb{R}^n \to \mathbb{R}$ 是定义在 $\mathbb{R}^n$ 上的强凸函数，则 f 是强制函数.

证明：$f(\mathbf{x})$ 是强凸函数，即 $g(\mathbf{x}) = f(\mathbf{x}) - \frac{m}{2}\|\mathbf{x}\|^2$ 是凸函数，其中 m 是强凸系数，对任意 $\mathbf{x},\mathbf{y} \in \mathbb{R}^n$ 有

$$g(\mathbf{y}) \geq g(\mathbf{x}) + \langle \nabla g(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle$$

代入 g 的表达式可得

$$f(\mathbf{y}) - \frac{m}{2}\|\mathbf{y}\|^2 \geq f(\mathbf{x}) - \frac{m}{2}\|\mathbf{x}\|^2 + \langle \nabla f(\mathbf{x}) - m\mathbf{x}, \mathbf{y} - \mathbf{x} \rangle$$

设 $\boldsymbol{\alpha} = \nabla f(\mathbf{x}) - m\mathbf{x}$，则上述不等式等价于

$$f(\mathbf{y}) \geq \frac{m}{2}\|\mathbf{y}\|^2 + \boldsymbol{\alpha}^\top \mathbf{y} + K_{\mathbf{x}}$$

其中 $K_{\mathbf{x}}$ 是与 $\mathbf{x}$ 有关的常数。由Cauchy－Schwarz不等式可得

$$f(\mathbf{y}) \geq \frac{m}{2}\|\mathbf{y}\|^2 - \|\boldsymbol{\alpha}\|\|\mathbf{y}\| + K_{\mathbf{x}}$$

当 $\|\mathbf{y}\| \to \infty$ 时，不等式右边 $\frac{m}{2}\|\mathbf{y}\|^2 - \|\boldsymbol{\alpha}\|\|\mathbf{y}\| + K_{\mathbf{x}} = (\frac{m}{2}\|\mathbf{y}\| - \|\boldsymbol{\alpha}\|)\|\mathbf{y}\| + K_{\mathbf{x}} \to \infty$，$f(\mathbf{y}) \to \infty$，因此 f 是强制函数.

无约束优化问题

$$\min_{\boldsymbol{x}\in\mathbb{R}^n} f(\boldsymbol{x}) \qquad (1)$$

- 根据最优解的定义，要验证一个点是否为优化问题的局部最优解，就要逐一比较该点的目标函数值和邻域内所有点的目标函数值的大小。这种方法效率很低，不可行。
- 如果目标函数$f(\boldsymbol{x})$ 是光滑的，就有许多有效和易操作的方法可以识别局部最优解。
  - ✓ 例如 $f(\boldsymbol{x})$如果是二阶连续可微函数，那么可以通过梯度 $\nabla f(\boldsymbol{x}^*)$、Hessian矩阵 $\boldsymbol{\nabla}^2 f(\boldsymbol{x}^*)$来判别$\boldsymbol{x}^*$是否是局部最优解，或是严格局部最优解。
- **最优性条件**是指取得最优解应该满足的必要或充分条件.

可行域与可行方向

设优化问题$\min f(\boldsymbol{x})$的可行域为 D

- 若 $\boldsymbol{x} \in D$, 则称 $\boldsymbol{x}$ 为可行点**(Feasible solution)**.
- 设 $\boldsymbol{x} \in D$, 对于 $\boldsymbol{0} \neq \boldsymbol{d} \in R^n$, 如果存在 $\alpha > 0$, 使得$\forall \delta \in [0, \alpha]$, $\boldsymbol{x} + \delta \boldsymbol{d} \in D$, 则称 $\boldsymbol{d}$ 为 $\boldsymbol{x}$ 处的可行方向，$\boldsymbol{x}$ 处所有可行方向构成的集合记为 $FD(\boldsymbol{x})$ 。

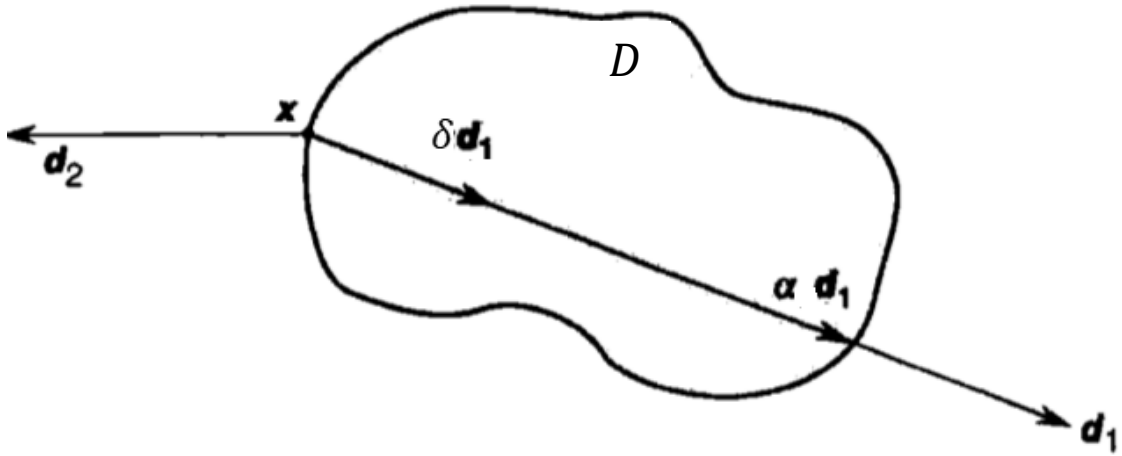

可行方向在二维空间内的演示。$\boldsymbol{d}_1$是一个可行方向，$\boldsymbol{d}_2$不是可行方向

内点的可行方向是任意的n维向量

无约束优化问题$\min\limits_{\boldsymbol{x} \in \mathbb{R}^n} f(\boldsymbol{x})$的可行域 $D = R^n$, 可行点都是内点，可行方向是任意的n维向量。

下降方向

设 $f: R^n \to R, \boldsymbol{x} \in R^n$ 和 $\boldsymbol{d} \in R^n, \boldsymbol{d} \neq \boldsymbol{0}$ 。如果存在一个数 $\tilde{t} > 0$ 使得

$$f(\boldsymbol{x} + t\boldsymbol{d}) < f(\boldsymbol{x}), \quad \text{for all} \quad t \in (0, \tilde{t}].$$

称 $\boldsymbol{d}$ 是 f 在 $\boldsymbol{x}$ 处的一个下降方向(Descent direction)。

从 $\boldsymbol{x}$ 沿下降方向$\boldsymbol{d}$ 的每一个足够小的步长都对应目标函数的严格减小。因此，局部最优点处不能有下降方向。

(一阶充分条件) 假设 $f: R^n \to R$ 在 $\boldsymbol{x} \in R^n$ 的邻域内连续可微，且 $\boldsymbol{d} \in R^n$ 为非零向量。如果

$$\nabla f(\boldsymbol{x})^T \boldsymbol{d} < 0$$

那么方向 $\boldsymbol{d}$ 在 $\boldsymbol{x}$ 处是 f 的下降方向。

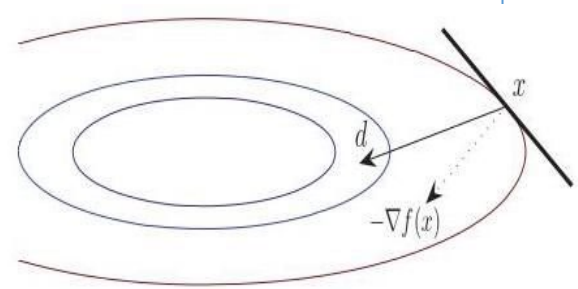

证明 在所述假设下， f 在 $\boldsymbol{x}$ 处的方向导数由下式给出

$$\lim_{t \to 0^+} \frac{f(\boldsymbol{x} + t\boldsymbol{d}) - f(\boldsymbol{x})}{t} = \nabla f(\boldsymbol{x})^T \boldsymbol{d}.$$

因此，如果 $\nabla f(\boldsymbol{x})^T \boldsymbol{d} < 0$ 上式意味着，对于足够小的 $t > 0$ 值以及连续性，必然有: $f(\boldsymbol{x} + t\boldsymbol{d}) - f(\boldsymbol{x}) < 0$ ，使得 $\boldsymbol{d}$ 是下降方向。

当 f 非凸时，可能在 x 处有下降方向 d，使得 $\nabla f(x)^T d = 0$。

例 函数$f(x) = x_1^2 - x_2^2$ 在点 $x = (0,0)$ 处。

梯度为 $\nabla f(x) = (2x_1, -2x_2)$，在 $x = (0,0)$ 处$\nabla f(0,0) = (0,0)$

因为梯度为零，任意方向 d 都满足 $\nabla f(x)^\top d = 0$

取方向 $d = (0,1)$，计算沿着 td 的函数值：

$$f(0,t) = -t^2$$

对于 $t > 0$，f 的值是负的（比 $f(0,0) = 0$ 小），也就是说，在方向 $\boldsymbol{d}$ 上函数值确实下降，$\boldsymbol{d} = (0,1)$ 是下降方向。

原因：泰勒展开式中一阶方向导数为零，二阶项主导

假设 $f: R^n \to R$ 在 $x \in R^n$ 的邻域内连续可微，f 在开球 $B(x;\rho)$ 内为凸函数，其中 $\rho > 0$，如果 d 在 x 处是下降方向，那么

$$\nabla f(x)^T d < 0。$$

证明　如果 f 在凸集 $B(x;\rho)$ 上是凸的，对于所有足够小的 $t \in \left(0, \frac{\rho}{\|d\|}\right)$ 值，有

$$x + td \in B(x;\rho) \text{ 且 } f(x+td) \geq f(x) + t\nabla f(x)^T d 。$$

因此，$\nabla f(x)^T d \geq 0$ 将意味着 $f(x+td) \geq f(x)$，因此，如果 d 是一个下降方向，必然有 $\nabla f(x)^T d < 0$。

设 $f: R^n \to R$ 在 $x \in R^n$ 的一个开邻域内二次连续可微。如果 $d^T \nabla^2 f(x) d < 0$，称 $d \in R^n, d \neq 0$ 是 f 在 x 处的**负曲率方向**。

(二阶充分条件) 设 $f: R^n \to R$ 在 $x \in R^n$ 的一个开邻域内二次连续可微，$d \in R^n$ 为非零向量。假设 $\nabla f(x)^T d = 0$，且 d 在 x 处是负曲率方向，即 $d^T \nabla^2 f(x) d < 0$。那么 d 在 x 处是 f 的一个下降方向。

证明 由于 f 具有二阶连续可微性，有:

$$f(x+td) = f(x) + t\nabla f(x)^T d + \frac{1}{2} t^2 d^T \nabla^2 f(x) d + \beta(x, td)$$

其中 $\lim_{t \to 0} \frac{\beta(x,td)}{t^2} = 0.$

根据假设 $\nabla f(x)^T d = 0$，有

$$\frac{f(x+td) - f(x)}{t^2} = \frac{1}{2} d^T \nabla^2 f(x) d + \frac{\beta(x, td)}{t^2}$$

$t \to 0$ 时，$\beta(x, td)/t^2 \to 0$，且 $d^T \nabla^2 f(x) d < 0$，对于足够小的 t 值，有

$f(x+td) - f(x) < 0$，因此 d 是一个下降方向。

局部极小值点的一阶必要条件

设 $x^* \in R^n$ 为 f 在 R^n 中的局部极小值点。那么在 x 处不可能存在 f 的下降方向。

证明:如果 d 在 x^* 处是一个下降方向，那么根据定义，我们可以在 x^* 的每个邻域中找到一个点 $x^* + td$，使得 $f(x^* + td) < f(x^*)$，而这将与 x^* 是局部极小值点的假设相矛盾。

设 $f(\boldsymbol{x})$ 在 $\boldsymbol{x}^* \in \mathbb{R}^n$ 处可微, 若 $\boldsymbol{x}^*$ 为无约束优化问题 $\min\limits_{\boldsymbol{x}\in\mathbb{R}^n} f(\boldsymbol{x})$的局部最优解, 则 $\nabla f(\boldsymbol{x}^*) = \boldsymbol{0}$.

证明　假设 $\nabla f(\boldsymbol{x}^*) \neq 0$ 。定义 $\boldsymbol{d} = -\nabla f(\boldsymbol{x}^*)$,满足

$$\boldsymbol{d}^T \nabla f(\boldsymbol{x}^*) = -\|\nabla f(\boldsymbol{x}^*)\|^2 < 0.$$

因此 $\boldsymbol{d}$ 是一个下降方向，这与 $\boldsymbol{x}^*$ 是局部最优解就产生了一个矛盾

几何意义：若 $\boldsymbol{x}^*$ 是局部解, 则在 $\boldsymbol{x}^*$ 处任何方向上的方向导数均为0, 即在 $\boldsymbol{x}^*$ 处的切平面是水平的.

定理的逆命题不成立, 即梯度为**0**的点不一定是局部解.

例 $min\left\{f(\boldsymbol{x})=x_1^3+x_2^2\right\}, \boldsymbol{x}\in\mathbf{R}^2$.

$f(\boldsymbol{x})$ 的梯度为 $\nabla f(\boldsymbol{x})=\left(3x_1^2,2x_2\right)^{\mathrm{T}}$. 在 $\bar{\boldsymbol{x}}=(0,0)^{\mathrm{T}}$, $\nabla f(\bar{\boldsymbol{x}})=\mathbf{0}$, 但是, 显然 $\bar{\boldsymbol{x}}$ 不是局部解, 因为对于所有的$\varepsilon>0$, 都有$f(-\varepsilon,0)=-\varepsilon^3<0=f(0,0)=f(\bar{\boldsymbol{x}})$

例 $\min\{f(\boldsymbol{x})=-x^2\}$, $x=0$不是极小点，是极大点。

- 满足$\nabla f(\boldsymbol{x})=\mathbf{0}$ 的点称为函数 $f(\boldsymbol{x})$ 的**驻点(Stationary Point)**、**稳定点**、**平稳点**、**临界点(Critical Point)**.
- 驻点可能是极小点, 也可能是极大点, 也可能不是极值点.
  - 既不是极小点也不是极大点的平稳点称为函数的**鞍点(saddle point)**.
- **拐点(inflection point)**是曲线凹凸性发生改变的点，是凹与凸的分界点。
- 驻点要求一阶导数必须存在，而**极值点**对导数没有要求。

如：y=|x| 在 x=0 处，是极小值点，但不是驻点，导数不存在。

鞍点(saddle point)

$f(x) = x^3$

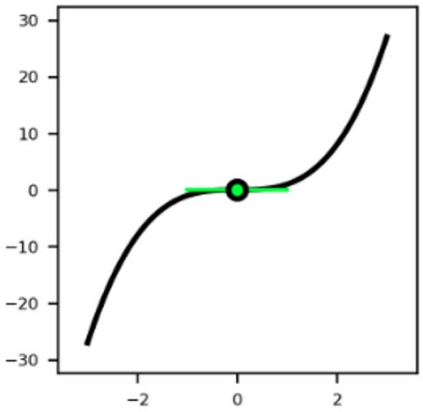

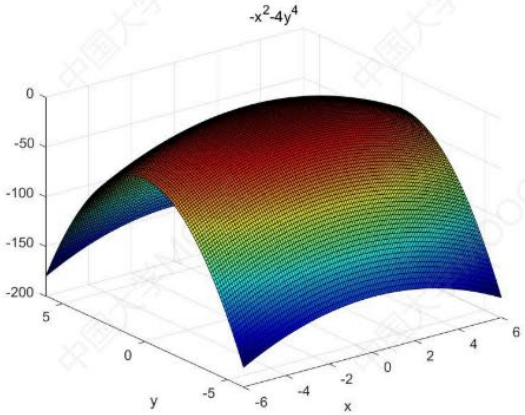

极大点

$-x^2 - 4y^4$

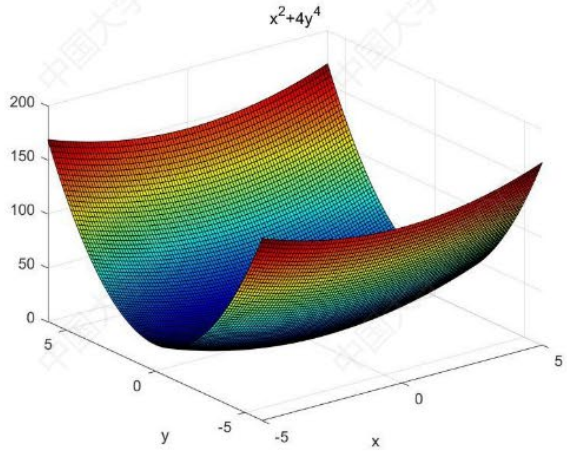

极小点

$x^2 + 4y^4$

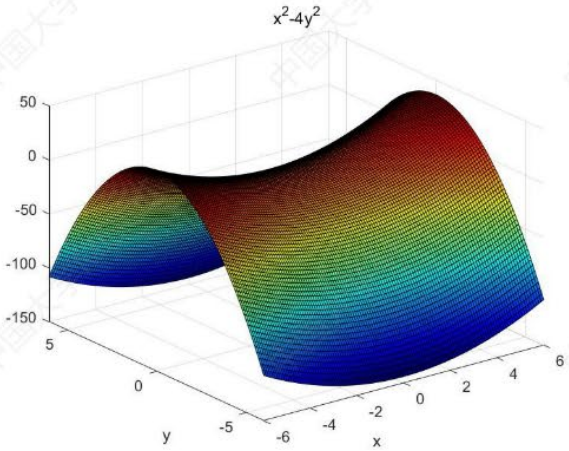

鞍点

$x^2 - 4y^4$

局部极小值点的二阶必要条件

设 $f: R^n \to R$ 在 $x^* \in R^n$ 的一个开邻域内二次连续可微。那么，如果 x^* 是 f 的一个无约束局部极小值点，则点 x^* 是 f 的一个驻点，并且 f 在 x^* 处的海森矩阵是半正定的，即:

(1) $\nabla f(x^*) = 0$;

(2) 对于所有的 $y \in R^n$， $y^T \nabla^2 f(x^*) y \geq 0$ 。

证明 由局部极小值点的一阶必要条件可得 (1).

如果(2)不成立，则必定存在 $y \in R^n$ 使得 $y^T \nabla^2 f(x^*) y < 0$ ，由于 $\nabla f(x^*)^T y = 0$ ，根据下降方向的二阶充分条件，方向 y 是 f 在 x^* 处的一个下降方向，这与 x^* 是局部极小值点的假设相矛盾。

二阶最优性条件:注记

- 设点$\bar{x}$ 满足一阶最优性条件(即$\nabla f(\bar{x}) = 0$), 且该点处的海瑟矩阵$\nabla^2 f(\bar{x})$ 不是半正定的, 那么$\bar{x}$ 不是一个局部极小点.
- 进一步地, 如果海瑟矩阵$\nabla^2 f(\bar{x})$ 既有正特征值又有负特征值, 我们称稳定点$\bar{x}$ 为一个鞍点.
- 事实上, 记d_1, d_2 为其正负特征值对应的特征向量, 那么对于任意充分小的$t > 0$, 我们都有$f(\bar{x} + td_1) > f(\bar{x})$ 且$f(\bar{x} + td_2) < f(\bar{x})$.
- 注意, 二阶最优性条件给出的仍然是关于局部最优性的判断.对于给定点的全局最优性判断, 我们还需要借助实际问题的性质, 比如目标函数是凸的、非线性最小二乘问题中目标函数值为0 等.

例 $f(x)=x^3$点x=0同时满是一阶和二阶必要条件，但不是极小点.

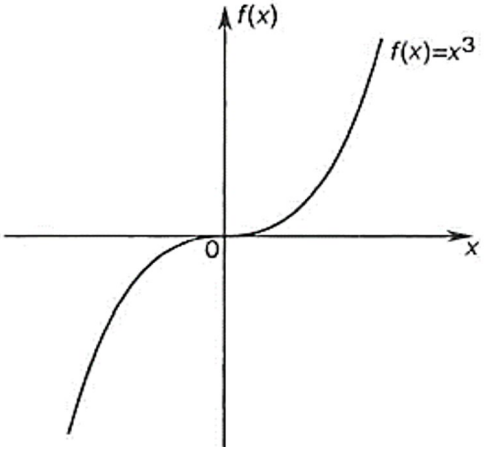

例 考虑如下问题

$$min\left\{f(\boldsymbol{x})=\frac{1}{2}x_1^2+x_1x_2+2x_2^2-4x_1-4x_2-x_2^3\right\}$$

其梯度为 $\nabla f(\boldsymbol{x})=\left(x_1+x_2-4,x_1+4x_2-4-3x_2^2\right)^{\mathrm{T}}$

Hesse 矩阵为 $\boldsymbol{\nabla}^2 f(\boldsymbol{x})=\begin{pmatrix}1 & 1\\ 1 & 4-6x_2\end{pmatrix}$

方程 $\boldsymbol{\nabla} f(\boldsymbol{x})=\boldsymbol{0}$ 有两个解: $\bar{\boldsymbol{x}}=(4,0)$ 及 $\tilde{\boldsymbol{x}}=(3,1)$.

$\nabla^2 f(\bar{\boldsymbol{x}})=\begin{pmatrix}1 & 1\\ 1 & 4\end{pmatrix}$是正定矩阵，$\bar{\boldsymbol{x}}=(4,0)$ 为极小点

$\nabla^2 f(\tilde{\boldsymbol{x}})=\begin{pmatrix}1 & 1\\ 1 & -2\end{pmatrix}$是不定矩阵, $\tilde{\boldsymbol{x}}=(3,1)$不是极小点

例 考虑二元实值函数 $f(\boldsymbol{x}) = x_1^2 - x_2^2, f: \mathbb{R}^2 \to \mathbb{R}$

$\nabla f(\boldsymbol{x}) = [2x_1, -2x_2]^\top = 0$, 可得到满足一阶必要条件的点, 即 $\boldsymbol{x} = [0,0]^\top$ 。

函数 f 的黑塞矩阵为 $\boldsymbol{F}(\boldsymbol{x}) = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$

$\boldsymbol{F}$ 是一个不定矩阵, 即对于某些向量 $\boldsymbol{d}_1 \in \mathbb{R}^2$ (如 $\boldsymbol{d}_1 = [1,0]^\top$), 有 $\boldsymbol{d}_1^\top \boldsymbol{F} \boldsymbol{d}_1 > 0$; 对于某些向量 $\boldsymbol{d}_2$ (如 $\boldsymbol{d}_2 = [0,1]^\top$), 又有 $\boldsymbol{d}_2^\top \boldsymbol{F} \boldsymbol{d}_2 < 0$ 。因此, $\boldsymbol{x} = [0,0]^\top$ 不满足二阶必要条件, 不是极小点。

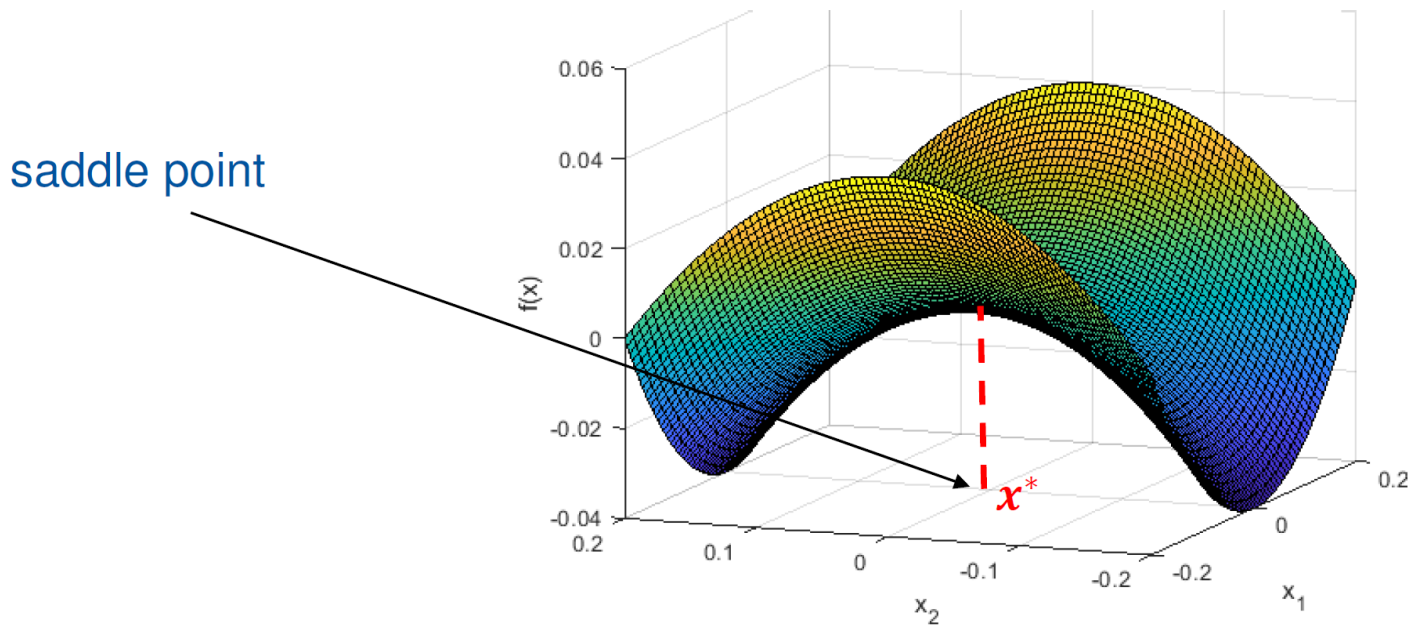

思考

能给出局部最优解的充分条件吗？

对于所有可行方向d，$d^T\nabla f(x)\geq 0$

x是内点，$d^T\nabla f(x)\geq 0$，$-d^T\nabla f(x)\geq 0$，则 $\nabla f(\boldsymbol{x}^*)=\mathbf{0}$ 必要条件

$$f(\boldsymbol{x}^*+\alpha\boldsymbol{d}) = f(\boldsymbol{x}^*)+\alpha\nabla f(\boldsymbol{x}^*)^T\boldsymbol{d}+o(\alpha)$$
$$= f(\boldsymbol{x}^*)+o(\alpha)$$

$o(\alpha)\geq 0$，能保证吗？

$$f(\boldsymbol{x}^*+\alpha\boldsymbol{d}) = f(\boldsymbol{x}^*)+\cancel{\alpha\nabla f(\boldsymbol{x}^*)^T\boldsymbol{d}}+\frac{1}{2}\alpha^2\boldsymbol{d}^T\nabla^2 f(\xi)\boldsymbol{d}.$$

$$\xi\in[\boldsymbol{x}^*,\boldsymbol{x}^*+\alpha\boldsymbol{d}]$$

$\boldsymbol{d}^T\nabla^2 f(\xi)\boldsymbol{d}\geq\mathbf{0}$ 可以吗？

设 $f(\boldsymbol{x})$ 二阶连续可微, 且满足 (1) $\nabla f(\boldsymbol{x}^*)=\mathbf{0}$ (2) $\nabla^2 f(\boldsymbol{x}^*)$ 为正定,
则 $\boldsymbol{x}^*$ 是无约束问题的一个**严格**局部解.

证明 对于 $\boldsymbol{x}^*\in\mathbf{R}^n, \boldsymbol{x}\neq\boldsymbol{x}^*$, 令 $\boldsymbol{d}=\frac{\boldsymbol{x}-\boldsymbol{x}^*}{\|\boldsymbol{x}-\boldsymbol{x}^*\|}$, 所以 $\|\boldsymbol{d}\|=1$. 于是 $\boldsymbol{x}=\boldsymbol{x}^*+\alpha\boldsymbol{d}, \alpha=\|\boldsymbol{x}-\boldsymbol{x}^*\|$ 。 $f(\boldsymbol{x})$在 $\boldsymbol{x}^*$ 处的二阶 Taylor 展开式

$$f(\boldsymbol{x})=f(\boldsymbol{x}^*+\alpha\boldsymbol{d})=f(\boldsymbol{x}^*)+\alpha\boldsymbol{d}^{\mathrm{T}}\nabla f(\boldsymbol{x}^*)+\frac{1}{2}\alpha^2\boldsymbol{d}^{\mathrm{T}}\nabla^2 f(\boldsymbol{x}^*)\boldsymbol{d}+o(\alpha^2).$$

因为 $\nabla f(\boldsymbol{x}^*)=\mathbf{0}$, 所以 $f(\boldsymbol{x})-f(\boldsymbol{x}^*)=\frac{1}{2}\alpha^2\boldsymbol{d}^{\mathrm{T}}\nabla^2 f(\boldsymbol{x}^*)\boldsymbol{d}+o(\alpha^2)$.

只须证明, 存在 $\varepsilon>0$, 当 $0<\alpha<\varepsilon$ 时, 上式右端大于0 .

由于函数 $F(\boldsymbol{d})=\boldsymbol{d}^{\mathrm{T}}\nabla^2 f(\boldsymbol{x}^*)\boldsymbol{d}$ 是闭球 $\{\boldsymbol{d}\mid\|\boldsymbol{d}\|=1\}$ 上的连续函数, 并且 $\nabla^2 f(\boldsymbol{x}^*)$ 为正定, 因此, 存在 $r>0$, 使得 $\boldsymbol{d}^{\mathrm{T}}\nabla^2 f(\boldsymbol{x}^*)\boldsymbol{d}\geqslant r$, （瑞利不等式）

$\frac{1}{2}\boldsymbol{d}^{\mathrm{T}}\nabla^2 f(\boldsymbol{x}^*)\boldsymbol{d}+\frac{o(\alpha^2)}{\alpha^2}\geqslant\frac{1}{2}r+\frac{o(\alpha^2)}{\alpha^2}$, 由于 $\frac{o(\alpha^2)}{\alpha^2}\to 0(\alpha\to 0)$, 因此, 存在$\bar{\alpha}>0$, 当 $0<\alpha<\bar{\alpha}$ 时, 上式右端大于0, 即 $f(\boldsymbol{x})-f(\boldsymbol{x}^*)>0$. 因此 $\boldsymbol{x}^*$ 是严格局部解. □

说明: 这个条件给出的是关于局部最优性的判断，不是全局最优性判断.

Review(瑞利不等式，Rayleigh)

如果 $n \times n$ 矩阵 $\boldsymbol{S}$ 是一个实对称矩阵, 则有

$$\lambda_{\min}(\boldsymbol{S}) \leqslant \frac{\mathbf{x}^T \boldsymbol{S} \mathbf{x}}{\| \mathbf{x} \|^2} \leqslant \lambda_{\max}(\boldsymbol{S})$$

其中, $\lambda_{\min}(\boldsymbol{S})$ 表示 $\boldsymbol{S}$ 的最小特征值, $\lambda_{\max}(\boldsymbol{S})$ 表示 $\boldsymbol{S}$ 的最大特征值。

证明 $\mathbf{U}^T \boldsymbol{S} \mathbf{U} = \mathbf{D}$, $\mathbf{D} = \mathrm{diag}(d_1, d_2, \dots, d_n)$, $d_1 \geq d_2 \geq \cdots \geq d_n$, $\mathbf{U}$是正交矩阵。

$d_1 = \lambda_{\max}(\boldsymbol{S}), d_n = \lambda_{\min}(\boldsymbol{S})$

$$\max_{\boldsymbol{x} \neq 0} \frac{\boldsymbol{x}^T \boldsymbol{S} \boldsymbol{x}}{\| \boldsymbol{x} \|^2} = \max_{\boldsymbol{y} \neq 0} \frac{\boldsymbol{y}^T \mathbf{U}^T \boldsymbol{S} \mathbf{U} \boldsymbol{y}}{\| \mathbf{U} \boldsymbol{y} \|^2} = \max_{\boldsymbol{y} \neq 0} \frac{\boldsymbol{y}^T \mathbf{D} \boldsymbol{y}}{\| \boldsymbol{y} \|^2} = \max_{\boldsymbol{y} \neq 0} \frac{\sum_{i=1}^n d_i y_i^2}{\sum_{i=1}^n y_i^2} \leq \frac{d_1 \left(\sum_{i=1}^n y_i^2 \right)}{\sum_{i=1}^n y_i^2} = d_1$$

$$= \lambda_{\max}(\boldsymbol{S})$$

$$\min_{\boldsymbol{x} \neq 0} \frac{\boldsymbol{x}^T \boldsymbol{S} \boldsymbol{x}}{\| \boldsymbol{x} \|^2} = \min_{\boldsymbol{y} \neq 0} \frac{\boldsymbol{y}^T \mathbf{U}^T \boldsymbol{S} \mathbf{U} \boldsymbol{y}}{\| \mathbf{U} \boldsymbol{y} \|^2} = \min_{\boldsymbol{y} \neq 0} \frac{\boldsymbol{y}^T \mathbf{D} \boldsymbol{y}}{\| \boldsymbol{y} \|^2} = \min_{\boldsymbol{y} \neq 0} \frac{\sum_{i=1}^n d_i y_i^2}{\sum_{i=1}^n y_i^2} \geq \frac{d_n \left(\sum_{i=1}^n y_i^2 \right)}{\sum_{i=1}^n y_i^2} = d_n$$

$$= \lambda_{\min}(\boldsymbol{S})$$

前面的例题中， $\nabla^2 f(\bar{x}) = \begin{pmatrix} 1 & 1 \\ 1 & 4 \end{pmatrix}$ 为正定矩阵, $\bar{\boldsymbol{x}}$ 满足无约束问题局部解的充分条件, 因此该点为严格局部解.

例 考虑函数 $f(\boldsymbol{x}) = x_1^2 + x_2^2$

当且仅当 $\boldsymbol{x} = [0,0]^\top$ 时, 函数的梯度 $\nabla f(\boldsymbol{x}) = [2x_1, 2x_2]^\top = \boldsymbol{0}$

对于所有的 $\boldsymbol{x} \in \mathbb{R}^2$, 有

$$\boldsymbol{F}(\boldsymbol{x}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} > 0$$

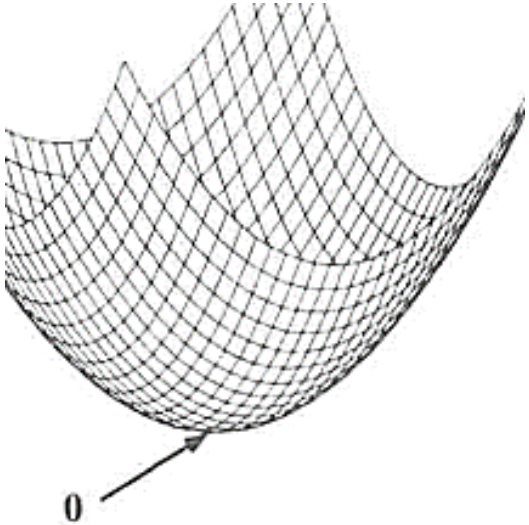

$\boldsymbol{x} = [0,0]^\top$ 同时满足一阶和二阶必要条件、二阶充分条件, 是一个严格局部极小点。实际上, 这也是一个严格全局极小点。

定理(二阶充分条件) 设 $f(\boldsymbol{x})$ 在点 $\boldsymbol{x}^* \in \mathbb{R}^n$ 的一个邻域 $N(\boldsymbol{x}^*, \delta)$ 内二次可微. 若在点 $\boldsymbol{x}^*$ 处满足 $\nabla f(\boldsymbol{x}^*) = 0$, 且 $\forall \boldsymbol{x} \in N(\boldsymbol{x}^*, \delta)$ 都有 $\nabla^2 f(\boldsymbol{x})$ 半正定, 则 $\boldsymbol{x}^*$ 是函数 $f(\boldsymbol{x})$ 的局部极小点.

例 求下列函数的极小点: $f(\boldsymbol{x}) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$.

解 (1) 求平稳点 $\begin{cases} 4(x_1 - 2)^3 + 2(x_1 - 2x_2) = 0 \\ -4(x_1 - 2x_2) = 0 \end{cases}$

解此方程组, 得到平稳点 $\boldsymbol{x}^* = (2,1)^T$.

(2) 判别黑塞矩阵的正定性 $\nabla^2 f(\boldsymbol{x}) = \begin{bmatrix} 12(x_1 - 2)^2 + 2 & -4 \\ -4 & 8 \end{bmatrix}$

在平稳点的黑塞矩阵为 $\nabla^2 f(\boldsymbol{x}^*) = \begin{bmatrix} 2 & -4 \\ -4 & 8 \end{bmatrix}$

该矩阵是半正定矩阵, 故不能直接判断 $\boldsymbol{x}^*$ 是否为局部极小点.

考虑邻域 $N(\boldsymbol{x}^*, \delta)$ 上的点 $\boldsymbol{x} = \boldsymbol{x}^* + \triangle \boldsymbol{x} = \begin{pmatrix} 2 + \triangle x_1 \\ 1 + \triangle x_2 \end{pmatrix}$, 则

$$\nabla^2 f(\boldsymbol{x}) = \begin{bmatrix} 12 \triangle x_1^2 + 2 & -4 \\ -4 & 8 \end{bmatrix}$$

容易验证上述矩阵是半正定的, 可知 $\boldsymbol{x}^*$ 是局部极小点.

例 考虑以下无约束优化问题:

$$min\ f(x_1,x_2)=\frac{1}{3}x_1^3+\frac{1}{2}x_1^2+2x_1x_2+\frac{1}{2}x_2^2-x_2+9$$

(1) 求目标函数所有的平稳点，并指出它们是局部极小或极大点;

(2) 该无约束优化问题是否存在全局极小或极大点?

解 (1) 令一阶导数等于零求出平稳点:

$$\nabla f(\boldsymbol{x})=\begin{pmatrix}x_1^2+x_1+2x_2\\2x_1+x_2-1\end{pmatrix}=0$$

$$\boldsymbol{x^1}=(2,-3)^T,\ \boldsymbol{x}^2=(1,-1)^T$$

$$\nabla^2 f(x)=\begin{pmatrix}2x_1+1 & 2\\2 & 1\end{pmatrix}$$

$\nabla^2 f(\boldsymbol{x^1})=\begin{pmatrix}5 & 2\\2 & 1\end{pmatrix}>0$， $\boldsymbol{x^1}$为严格局部极小点;

$\nabla^2 f(\boldsymbol{x}^2)=\begin{pmatrix}3 & 2\\2 & 1\end{pmatrix}$ 非半正定, $\boldsymbol{x}^2$不是局部极值点。

(2) $f(x_1,0)=\frac{1}{3}x_1^3+\frac{1}{2}x_1^2+9$，随着$x_1\to\pm\infty$， $f\to\pm\infty$，不存在全局极小或极大点。

几个条件之间的关系

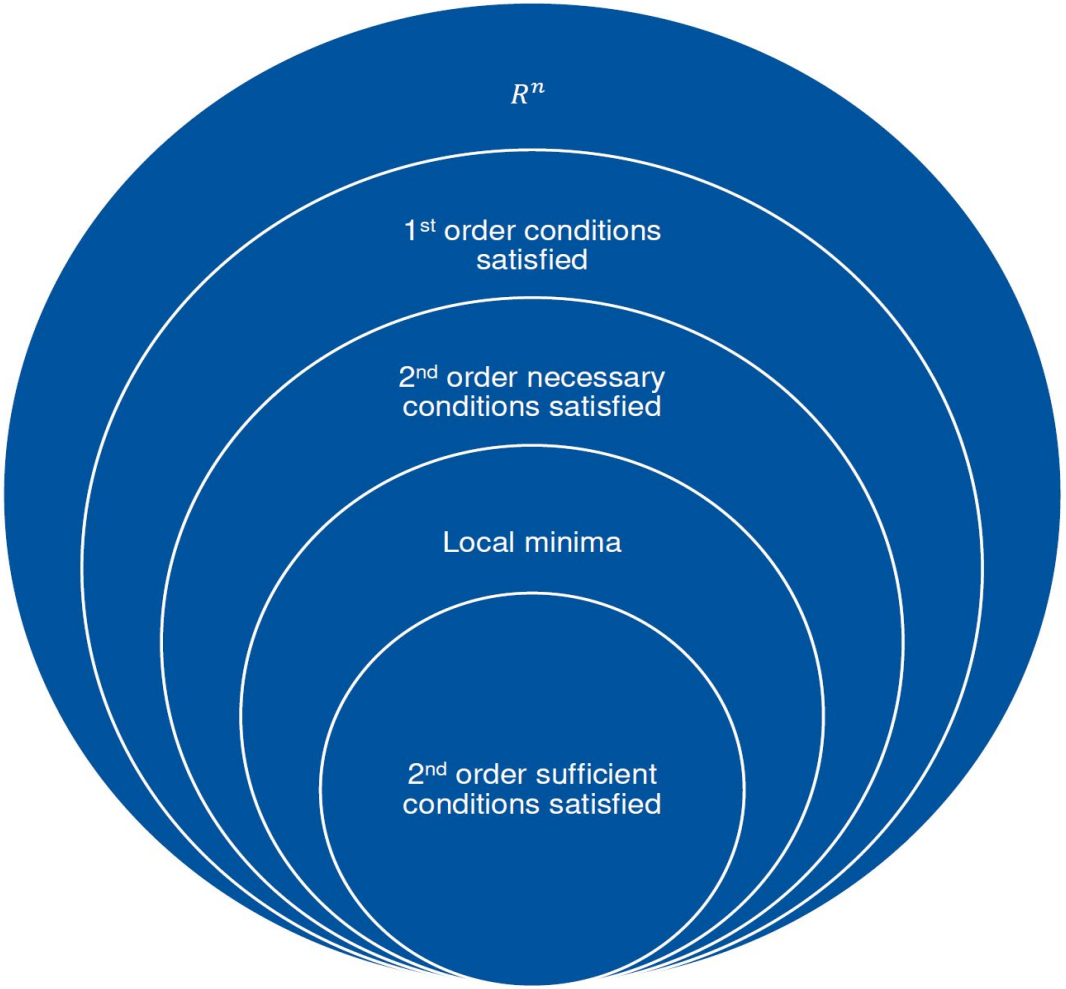

一般地，非线性最优化的数值求解算法只能保证求得的点满足一阶必要条件，而不能保证满足二阶充分条件。

填空题 3分

设置

二元实值函数 $f: \mathbb{R}^2 \to \mathbb{R}$ 为

$$f(\boldsymbol{x}) = (x_1 - x_2)^4 + x_1^2 - x_2^2 - 2x_1 + 2x_2 + 1$$

其中, $\boldsymbol{x} = [x_1, x_2]^\mathsf{T}$。约束集为 $\mathbb{R}^2$, 求 f 的极小值。

满足一阶必要条件的点：x_1=[填空1] x_2=[填空2]
是局部极小点吗（Y/N）？ [填空3]

正常使用填空题需3.0以上版本雨课堂

作答

无约束可微凸优化的充要条件

若 $f: \mathbf{R}^n \to \mathbf{R}$ 是凸函数, 且 $f(\boldsymbol{x})$ 一阶连续可微,则 $\boldsymbol{x}^*$ 是全局最小解的**充分必要条件**是 $\nabla f(\boldsymbol{x}^*) = \mathbf{0}$.

证明

充分性 因为 f 是 $\mathbf{R}^n$ 上的可微凸函数, $\nabla f(\boldsymbol{x}^*) = \mathbf{0}$, 故有

$$f(\boldsymbol{x}) \geqslant f(\boldsymbol{x}^*) + \boldsymbol{\nabla f}(\boldsymbol{x}^*)^{\mathrm{T}}(\boldsymbol{x} - \boldsymbol{x}^*) = f(\boldsymbol{x}^*), \forall \boldsymbol{x} \in \mathbf{R}^n,$$

这表明 $\boldsymbol{x}^*$ 是 $f(\boldsymbol{x})$ 的全局极小点.

必要性 由一阶必要条件得到。

例 考虑以下无约束优化问题:

$$min\ f(x_1, x_2) = 8x_1^2 + 3x_1x_2 + 7x_2^2 - 19x_1 - 17x_2 - 29$$

(1) 求目标函数所有的驻点;

(2) 平稳点是否为局部极小点?

(3) 该问题是否存在全局极小点?

解 令一阶导数等于零,

$$\nabla f(x) = \begin{pmatrix} 16x_1 + 3x_2 - 19 \\ 3x_1 + 14x_2 - 17 \end{pmatrix} = 0$$

解得驻点 $x^0 = (1,1)^T$

再求二阶导数:

$$\nabla^2 f(\boldsymbol{x}) = \begin{pmatrix} 16 & 3 \\ 3 & 14 \end{pmatrix} > 0$$

Hessian矩阵正定, 目标函数为凸函数，因此驻点为严格局部极小点，也是全局极小点。

例 (二次函数的极小化) 设 $q(x) = \frac{1}{2}x^T Qx + c^T x$，其中 Q 对称且 $c \in R^n$ 。那么:

(1) q 有全局最小值当且仅当 Q 是半正定矩阵且存在 x^* 使得 $Qx^* + c = 0$；

(2) q 有唯一全局最小点当且仅当 Q 是正定矩阵。

证明

(1) 假设 $Qx^* + c = 0$ 且 Q 是半正定矩阵。这意味着 q 是凸函数，因此，由于 $\nabla q(x^*) = Qx^* + c = 0$，可知 $x^\star$ 是最优解。

反之，如果 q 有最小点 x^*，有 $\nabla q(x^*) = 0$且海森矩阵 $\nabla^2 q(x^*) = Q$ 是半正定矩阵。

(2) 如果 Q 是正定的，那么 q 是严格凸函数且 $Qx + c = 0$ 有唯一解 x^*，因为 Q 是非奇异的。这意味着 $x^\star$ 是 q 的唯一全局最小值。

反之，假设 x^* 是唯一的最小点。那么，由 (1)知道 Q 是半正定矩阵且 $Qx + c = 0$ 有解。由于全局最小值是唯一的，$Qx + c = 0$的矩阵 Q 必须是非奇异的，因此是正定的。

例 线性最小二乘问题(Linear Least Squares)

求解方程组 $A\boldsymbol{x} \cong \boldsymbol{b}$ 的一种方法是转换为线性最小二乘问题:

$$\min_{x\in\mathbb{R}^n}\left\{f(\boldsymbol{x}) = \frac{1}{2}\parallel A\boldsymbol{x} - \boldsymbol{b}\parallel_2^2\right\}, A \in \mathbb{R}^{m\times n}$$

这是一个无约束二次目标函数的优化问题.

根据 $A^{\mathrm{T}}A$ 的半正定性，二次函数 f 是凸函数, 故 $\boldsymbol{x} \in \mathbb{R}^n$ 为其全局极小解当且仅当 $\boldsymbol{x}$ 满足方程

$$\nabla f(\boldsymbol{x}) = A^{\mathrm{T}}(A\boldsymbol{x} - \boldsymbol{b}) = 0.$$

最小值点$\boldsymbol{x}^*$一定满足 $n \times n$ 的对称线性方程组(**正规方程组**)

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}^* = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$$

正规方程组的几何意义

对于$A \in \mathbb{R}^{m\times n}$，$m > n$ 的最小二乘问题, m 维向量 $\boldsymbol{b}$ 一般不属于 span($\boldsymbol{A}$), 子空间 span($\boldsymbol{A}$) 的维数最大为 n. 当残差向量 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}$ 垂直于 span($\boldsymbol{A}$) 时, 向量 $\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x} \in$ span($\boldsymbol{A}$) 在欧几里得范数意义下是最接近 $\boldsymbol{b}$ 的. 这样, 对于最小二乘解 $\boldsymbol{x}$, 残差向量 $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}$垂直于 $\boldsymbol{A}$ 的各列, 因此 $\mathbf{0} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{r} = \boldsymbol{A}^{\mathrm{T}}(\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x})$, $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$.

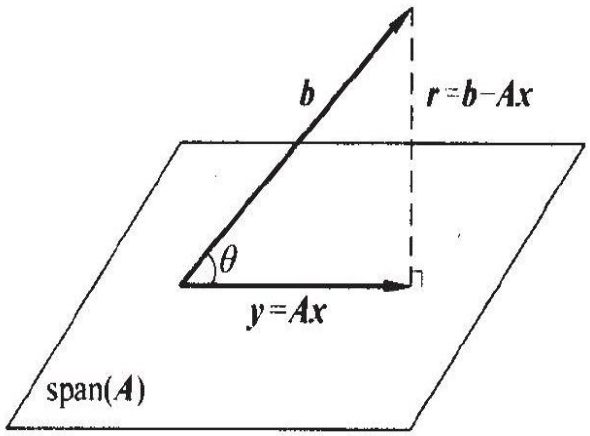

正规方程组的解

- 如果 A 是列满秩, 则$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$为正定矩阵(可逆), $\boldsymbol{x}^* = \left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\right)^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 就是线性最小二乘问题的严格全局极小点。
- 当$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$不正定($A^T A \succeq 0$)时，目标函数 f 是凸函数，此时解不唯一。

  设$\boldsymbol{x}_0$是$A^T A\boldsymbol{x} = A^T\boldsymbol{b}$的一个非零解，则$\boldsymbol{x} \in \boldsymbol{x}_0 + \mathcal{N}(A^T A)$也是最优解

- $A^T A\boldsymbol{x} = A^T\boldsymbol{b}$ 总有解，即$A^T\boldsymbol{b} \in \mathrm{span}(A^T A)$

引理 Suppose A is an m by n real matrix. The span of columns of AA^T is the same as the span of columns of A，即 $\mathrm{span}(AA^T) = \mathrm{span}(A)$。

推论 $\mathrm{span}(A^T A) = \mathrm{span}(A^T)$

证明 $b \in \mathrm{span}(B)$ if and only if $Bx = b$ is consistent.

$\mathrm{span}(AA^T) \subset \mathrm{span}(A)$ is clear. We prove $\mathrm{span}(A) \subset \mathrm{span}(AA^T)$.

Let $b \in \mathrm{span}(A)$. Then, there exists some x so that $Ax = b$.

Let $y = \mathrm{proj}_{\mathrm{span}(A^T)}\, x$. This means that $y \in \mathrm{span}(A^T)$ and $x - y \perp \mathrm{span}(A^T)$.

Let $y = A^T z \Rightarrow AA^T z = Ay$ and $x - y \perp \mathrm{span}(A^T) = \mathrm{Row}(A)$

$$\Rightarrow A(x - y) = \mathbf{0} \Rightarrow Ay = Ax = b$$

$$\Rightarrow AA^T z = b \Rightarrow b \in \mathrm{span}(AA^T)$$

线性最小二乘问题$A\boldsymbol{x} \cong \boldsymbol{b}$中，求解正规方程组

$$\boldsymbol{A}^\top \boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^\top \boldsymbol{b}$$

的条件数$\kappa(\boldsymbol{A}^\top \boldsymbol{A}) = \frac{\lambda_{max}\{\boldsymbol{A}^\top \boldsymbol{A}\}}{\lambda_{min}\{\boldsymbol{A}^\top \boldsymbol{A}\}} = \frac{\sigma_1\{\boldsymbol{A}^\top \boldsymbol{A}\}}{\sigma_n\{\boldsymbol{A}^\top \boldsymbol{A}\}}$

实际应用中，$\boldsymbol{A}^\top \boldsymbol{A}$往往不是满秩矩阵（即不可逆），或即使可逆，条件数也很大，导致方程组的解不健壮，受扰动影响大。

这时可以用添加**正则项(regularizer)**的办法，使得问题的目标函数是严格凸的，解的性质得到改善。

Tikhonov正则化/岭回归(ridge regression)

给所有特征值加上一个正数λ，可以使条件数变小。

例如 $\lambda_{max}\{\boldsymbol{A}^\top\boldsymbol{A}\} = 5, \lambda_{min}\{\boldsymbol{A}^\top\boldsymbol{A}\} = 0.01, \kappa(\boldsymbol{A}^\top\boldsymbol{A}) = 500$,

加上3以后，$\kappa(\boldsymbol{A}^\top\boldsymbol{A}) = 8/3.01 = 2.65$

这相当于求解 $(\boldsymbol{A}^\top\boldsymbol{A} + \lambda\boldsymbol{I})\boldsymbol{x} = \boldsymbol{A}^\top\boldsymbol{b}$，即求解方程组 $\begin{bmatrix} A \\ \sqrt{\lambda}I \end{bmatrix}\boldsymbol{x} \cong \begin{bmatrix} \boldsymbol{b} \\ \vec{0} \end{bmatrix}$.

对应的优化问题：$\min\limits_{x\in\mathbb{R}^n}\{\| A\boldsymbol{x} - \boldsymbol{b} \|_2^2 + \lambda \| \boldsymbol{x} \|_2^2\}, A \in \mathbb{R}^{m\times n}$

称为**岭回归(ridge regression)**。实际上是为了平衡模型的拟合性质和解的光滑性, 添加了 l_2 范数平方为正则项。

$$\nabla_x\left\{\|Ax - \mathrm{b}\|_2^2 + \lambda\|x\|_2^2\right\} = \nabla_x x^\mathrm{T}A^\mathrm{T}Ax - 2\mathrm{b}^\mathrm{T}Ax + \mathrm{b}^\mathrm{T}\mathrm{b} + \lambda x^\mathrm{T}x$$
$$= 2A^\mathrm{T}Ax - 2A^\mathrm{T}\mathrm{b} + 2\lambda x = 2(A^\mathrm{T}A + \lambda I)x - 2A^\mathrm{T}\mathrm{b}$$

如果$A^\mathrm{T}A + \lambda I$是正定矩阵，优化问题是严格凸优化，有唯一解。

例 去噪

$\mathbf{b} = \mathbf{x} + \mathbf{w}$ $\mathbf{x} \in \mathbb{R}^n$是未知量，$\mathbf{b}$是观测量，$\mathbf{w}$是未知噪声

$\min \| \mathbf{x} - \mathbf{b} \|^2$ 最优解是 $\mathbf{x}^* = \mathbf{b}$, 没有意义。

假设信号是光滑的，增加正则项 $R(\mathbf{x}) = \sum_{i=1}^{n-1}(x_i - x_{i+1})^2 = \| \mathbf{Lx} \|_2^2$

$$\mathbf{L} = \begin{pmatrix} 1 & -1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 1 & -1 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 1 & -1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & 0 & 0 & & 1 & -1 \end{pmatrix} \in \mathbb{R}^{(n-1)\times n}$$

$$\min_{\mathbf{x}} \| \mathbf{x} - \mathbf{b} \|^2 + \lambda \| \mathbf{Lx} \|^2$$

最优解是 $\mathbf{x}_{\mathrm{RLS}}(\lambda) = \left(\mathbf{I} + \lambda \mathbf{L}^T \mathbf{L}\right)^{-1} \mathbf{b}$

例如 $x_i = \sin\left(4\frac{i-1}{299}\right) + \left(4\frac{i-1}{299}\right)\cos^2\left(4\frac{i-1}{299}\right), i = 1,2,\ldots,300$
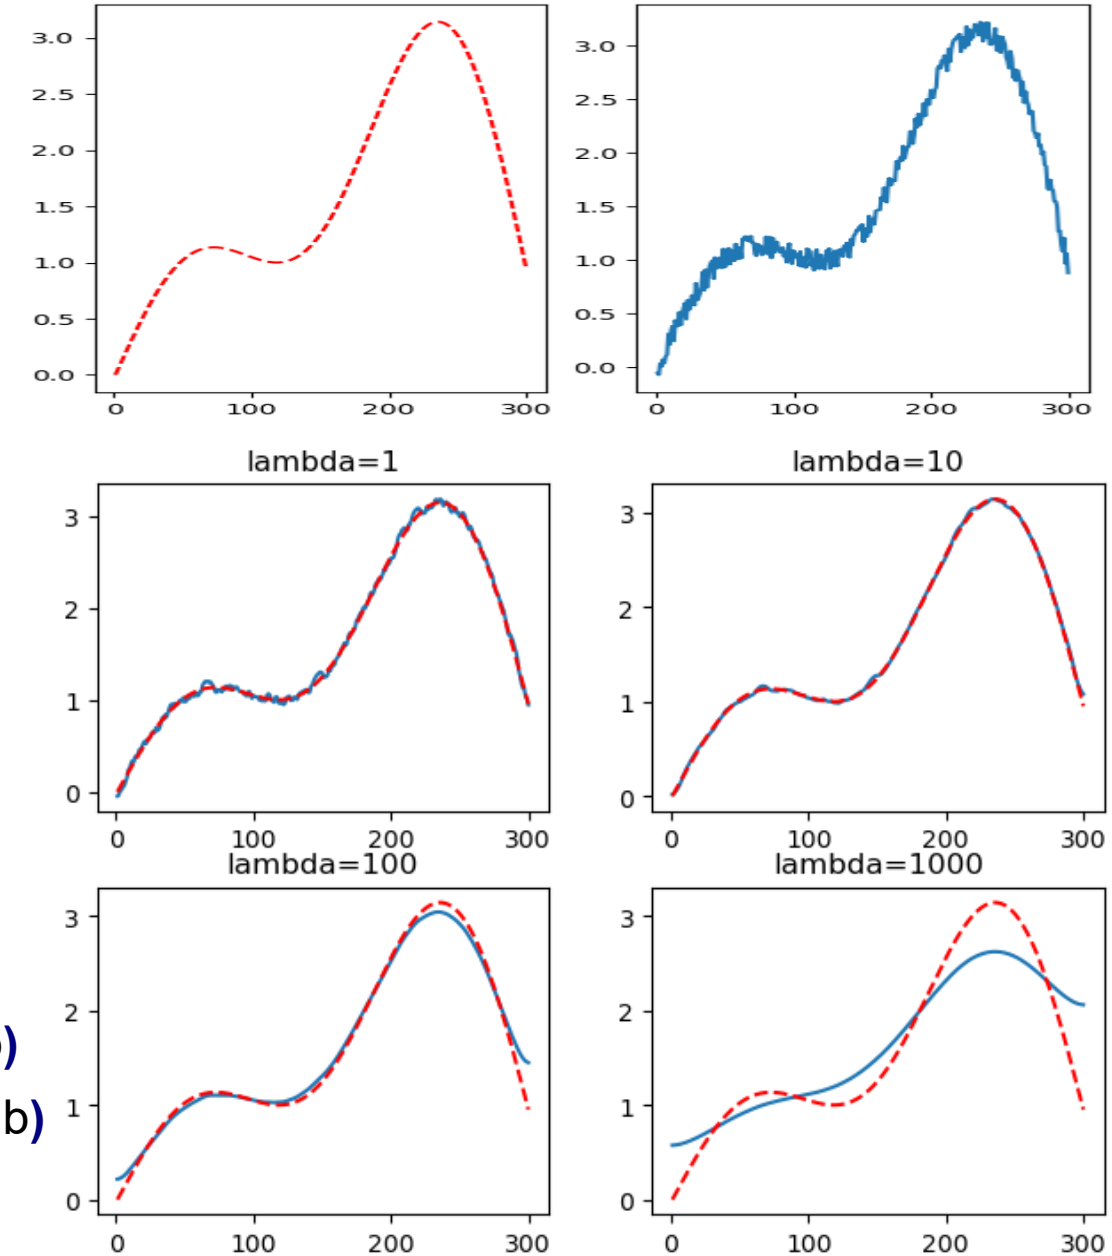
```
import numpy as np
import numpy.linalg as la
t = np.linspace(0, 4, num = 300)
x = np.sin(t) + t * (np.cos(t)**2)
w = np.arange(1, 301)
b = x + 0.1 * np.sin(10 * w**3)
L= np.zeros((299, 300))
for i in range(299):
    L[i, i] = 1
    L[i, i+1] = -1
I= np.eye(300)
LTL = L.T @ L
x_rls0 = la.solve(I + LTL, b)
x_rls1 = la.solve(I + 10 * LTL, b)
x_rls2 = la.solve(I + 100 * LTL, b)
x_rls3 = la.solve(I + 1000 * LTL, b)
```