最优化理论与方法
Optimization Theory and Methods

约束优化的对偶理论

Duality with constrained optimization

- 拉格朗日函数
- 拉格朗日对偶函数
- 拉格朗日对偶问题
- 弱对偶性
- 强对偶性
- Slater条件

对偶理论: 一般的约束优化问题

$$
\begin{aligned}
\min_{x\in\mathbb{R}^n} \quad & f(x), \\
\text{s.t.} \quad & c_i(x) \le 0,\ i \in \mathcal{I}, \\
& c_i(x) = 0,\ i \in \mathcal{E},
\end{aligned}
\tag{1}
$$

其中c_i 为定义在$\mathbb{R}^n$ 或其子集上的实值函数, $\mathcal{I}$ 和$\mathcal{E}$ 分别表示不等式约束和等式约束对应的下标集合且各下标互不相同.

- 这个问题的可行域定义为

$$
\mathcal{X} = \{x \in \mathbb{R}^n \mid c_i(x) \le 0,\ i \in \mathcal{I} \text{ 且 } c_i(x) = 0,\ i \in \mathcal{E}\}.
$$

思路：通过无约束优化问题寻找问题(1)的最优值的下界

例 优化问题(P)

$$\begin{aligned} \min \quad & x_1^2 + x_2^2 + 2x_1 \\ \text{s.t.} \quad & x_1 + x_2 = 0. \end{aligned}$$

最优解$(x_1, x_2)^* = \left(-\frac{1}{2}, \frac{1}{2}\right)$，最优值$f^* = -\frac{1}{2}$.

- 直接去掉约束条件，得到问题(P_0)：

$$\min x_1^2 + x_2^2 + 2x_1.$$

问题(P_0)的最优值是问题(P) 的最优值下界，即：$\mathrm{val}(\mathrm{P}_0) \le \mathrm{val}(\mathrm{P})$

问题(P_0)是个凸优化问题，最优解是$x_1 = -1, x_2 = 0$，最优值是-1($< f^* = -\frac{1}{2}$).

- 在目标函数中增加一项，得到问题(P)的等价问题：

$$\begin{aligned} \min \ & x_1^2 + x_2^2 + 2x_1 + \mu(x_1 + x_2) \\ \text{s.t.} \ & x_1 + x_2 = 0. \end{aligned}$$

去掉约束条件，得到问题(P_μ)：

$$\min x_1^2 + x_2^2 + 2x_1 + \mu(x_1 + x_2)$$

对所有的$\mu \in \mathbb{R}$，$\mathrm{val}(\mathrm{P}_\mu) \le \mathrm{val}(\mathrm{P})$

问题(P_μ) 的最优解是 $(x_1, x_2) = \left(-1-\frac{\mu}{2}, -\frac{\mu}{2}\right)$,

最优值$q(\mu) \equiv \mathrm{val}(\mathrm{P}_\mu) = \left(-1-\frac{\mu}{2}\right)^2 + \left(-\frac{\mu}{2}\right)^2 + 2\left(-1-\frac{\mu}{2}\right) + \mu(-1-\mu) = -\frac{\mu^2}{2} - \mu - 1.$

当$\mu = 0$时，$q(0) = -1$ 是由问题(P_0)得到的问题(P)的下界.

取不同的μ，得到问题(P)的下界集合，在下界集合中寻找最大的下界。

- 最大的下界是问题(D)的解：

$$\max\{q(\mu): \mu \in \mathbb{R}\} = \max_{\mu} \min_{x} x_1^2 + x_2^2 + 2x_1 + \mu(x_1 + x_2) \qquad \text{(D)}$$

问题(D)称为问题(P)（称为原问题，primal problem ）的对偶问题(dual problem)，其最优值是问题(P)的下界:

$$\mathrm{val(D)} \le \mathrm{val(P)}$$

这里，对偶问题的最优解是$\mu^* = -1$ ，最优值是$-\frac{1}{2}$ （恰好等于f^*，一般情况下通常不成立）。

例　优化问题(P)

$$\begin{aligned} min \quad & -x^2 \\ \text{s.t.} \quad & x = 1 \end{aligned}$$

容易得到$f^* = -1$.

- 在目标函数中增加一项，得到问题(P)的等价问题：

$$\begin{aligned} \min\ L(x, \lambda_1, \lambda_2) &= -x^2 + \mu(1 - x) \\ \text{s. t.}\ \ x &= 1. \end{aligned}$$

去掉约束条件，得到无约束优化问题(P_μ)：

$$\min_x -x^2 + \mu(1 - x)$$

对所有的$\mu \in \mathbb{R}$，$\mathrm{val}(\mathrm{P}_\mu) = -\infty$

这里，对偶问题的最优值是$-\infty$，非常差的下界。

等式约束的处理

问题(P)：$\min\ f(x) \quad \text{s.t.}\ \ c(x) = 0$

在目标函数中增加一项，得到等价问题(Q)：

$$\min\ f(x) + \nu c(x)$$
$$\text{s.t.}\ \ c(x) = 0$$

其中$\nu \in \mathbb{R}$，$\mathrm{val}(\mathrm{Q}) = \mathrm{val}(\mathrm{P})$

去掉问题(Q)的约束条件，得到无约束优化问题(P_ν)：

$$\min f(x) + \nu c(x)$$

对所有的$\nu \in \mathbb{R}$，$\mathrm{val}(\mathrm{P}_\nu) \leq \mathrm{val}(\mathrm{P})$

不等式约束的处理

问题(P)：$\min\ f(x) \quad \text{s.t.}\ \ c(x) \leqslant 0$

在目标函数中增加一项，得到问题(Q)：

$$\min\ f(x) + \lambda c(x)$$
$$\text{s.t.}\ \ c(x) \leqslant 0$$

如果$\lambda \in \mathbb{R}$，这两个问题等价吗？

分析：$\lambda < 0$时，$\lambda c(x) \geqslant 0$，$\mathrm{val(Q)} \geq \mathrm{val(P)}$

$\lambda \geqslant 0$时，$\lambda c(x) \leq 0$，$\mathrm{val(Q)} \leq \mathrm{val(P)}$

去掉问题(Q)的约束条件，得到无约束优化问题(P_λ)：

$$\min f(x) + \lambda c(x)$$

对所有的$\lambda \geqslant 0$，$\mathrm{val}(\mathrm{P}_\lambda) \leq \mathrm{val(P)}$

拉格朗日函数 (Lagrangian)

一般的约束优化问题:

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & c_i(x) \le 0,\ i \in \mathcal{I},\ |\mathcal{I}| = m \\ & c_i(x) = 0,\ i \in \mathcal{E},\ |\mathcal{E}| = p \end{aligned} \tag{1}$$

变量$x \in \mathbb{R}^n$, 最优值为p^*, 定义域为

$$\mathcal{X} = \{x \in \mathbb{R}^n \mid c_i(x) \le 0,\ i \in \mathcal{I} \text{ 且 } c_i(x) = 0,\ i \in \mathcal{E}\}$$

拉格朗日函数$L : \mathbb{R}^n \times \mathbb{R}^m_+ \times \mathbb{R}^p \to \mathbb{R}$

$$L(x, \lambda, \nu) = f(x) + \sum_{i \in \mathcal{I}} \lambda_i c_i(x) + \sum_{i \in \mathcal{E}} \nu_i c_i(x)$$

- λ_i 为第i 个不等式约束对应的拉格朗日乘子
- ν_i 为第i 个等式约束对应的拉格朗日乘子

拉格朗日对偶函数

拉格朗日对偶函数$g:\mathbb{R}_+^m \times \mathbb{R}^p \rightarrow [-\infty,+\infty)$

$$g(\lambda,\nu)=\inf_{x\in\mathbb{R}^n} L(x,\lambda,\nu)$$

$$=\inf_{x\in\mathbb{R}^n}\left(f(x)+\sum_{i\in\mathcal{I}}\lambda_i c_i(x)+\sum_{i\in\mathcal{E}}\nu_i c_i(x)\right)$$

- 对于固定的λ,ν来说，这是个**无约束优化问题**。
- 拉格朗日对偶函数 $g(\boldsymbol{\lambda},\boldsymbol{\nu})$ 是凹函数。

  对于固定的$\boldsymbol{x}$来说，拉格朗日函数 $L(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu})$是$\boldsymbol{\lambda},\boldsymbol{\nu}$的仿射函数(凹函数)。

  拉格朗日对偶函数$g(\boldsymbol{\lambda},\boldsymbol{\nu})$是对凹函数逐点求下确界，必然是一个凹函数。

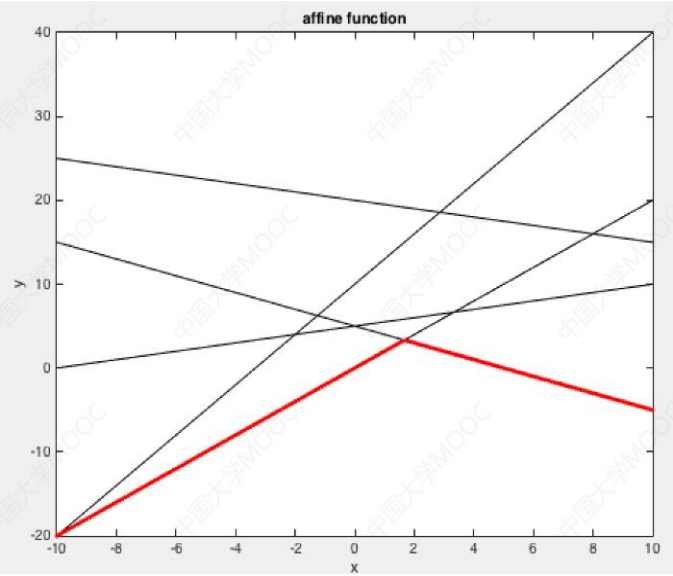

拉格朗日对偶函数 $g(\boldsymbol{\lambda},\boldsymbol{\nu})$ 是凹函数.

证明　设 $\boldsymbol{\lambda}^1,\boldsymbol{\lambda}^2 \in \mathbf{R}_+^m, \boldsymbol{\nu}^1,\boldsymbol{\nu}^2 \in \mathbf{R}^p$. 令 $\alpha \in (0,1)$, 则

$$g\left(\alpha\boldsymbol{\lambda}^1 + (1-\alpha)\boldsymbol{\lambda}^2, \alpha\boldsymbol{\nu}^1 + (1-\alpha)\boldsymbol{\nu}^2\right)$$

$$= \inf\left\{f(\boldsymbol{x}) + \sum_{i\in\mathcal{I}} \left(\alpha\lambda_i^1 + (1-\alpha)\lambda_i^2\right)c_i(\boldsymbol{x}) + \sum_{i\in\mathcal{E}} \left(\alpha\nu_i^1 + (1-\alpha)\nu_i^2\right)c_i(\boldsymbol{x})\right\}$$

$$= inf\left\{\alpha\left(f(\boldsymbol{x}) + \sum_{i\in\mathcal{I}} \lambda_i^1 c_i(\boldsymbol{x}) + \sum_{i\in\mathcal{E}} \nu_i^1 c_i(\boldsymbol{x})\right) + (1-\alpha)\left(f(\boldsymbol{x}) + \sum_{i\in\mathcal{I}} \lambda_i^2 c_i(\boldsymbol{x}) + \sum_{i\in\mathcal{E}} \nu_i^2 c_i(\boldsymbol{x})\right)\right\}$$

$$\geqslant \alpha\, inf\left\{\left(f(\boldsymbol{x}) + \sum_{i\in\mathcal{I}} \lambda_i^1 c_i(\boldsymbol{x}) + \sum_{i\in\mathcal{E}} \nu_i^1 c_i(\boldsymbol{x})\right)\right\} + (1-\alpha)\, inf\left\{\left(f(\boldsymbol{x}) + \sum_{i\in\mathcal{I}} \lambda_i^2 c_i(\boldsymbol{x}) + \sum_{i\in\mathcal{E}} \nu_i^2 c_i(\boldsymbol{x})\right)\right\}$$

$$= \alpha g(\boldsymbol{\lambda}^1,\boldsymbol{\nu}^1) + (1-\alpha)g\left(\boldsymbol{\lambda}^2,\boldsymbol{\nu}^2\right)$$

因此, $g(\boldsymbol{\lambda},\boldsymbol{\mu})$是凹函数.

对于任意的 $\lambda \geqslant 0$ 和 ν, 拉格朗日对偶函数给出了优化问题(1)最优值的一个下界, 即

$$g(\lambda, \nu) \leqslant p^*,\ \lambda \geqslant 0$$

证明 假设 $\tilde{x}$ 是问题(1)的一个可行解, 即 $c_i(\tilde{x}) \leqslant 0, i \in \mathcal{I}$ 和 $c_i(\tilde{x}) = 0, i \in \mathcal{E}$ 对于任意的 i 均成立. 由于 $\lambda \geqslant 0$, 则

$$\sum_{i \in \mathcal{I}} \lambda_i c_i(\tilde{x}) + \sum_{i \in \mathcal{E}} \nu_i c_i(\tilde{x}) \leqslant 0.$$

将上式代入拉格朗日函数的定义中, 可以得到

$$L(\tilde{x}, \lambda, \nu) = f(\tilde{x}) + \sum_{i \in \mathcal{I}} \lambda_i c_i(\tilde{x}) + \sum_{i \in \mathcal{E}} \nu_i c_i(\tilde{x}) \leqslant f(\tilde{x}),$$

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) \leqslant L(\tilde{x}, \lambda, \nu) \leqslant f(\tilde{x}).$$

所以对于任意的可行解 $\tilde{x}, g(\lambda, \nu) \leqslant f(\tilde{x})$ 都成立, 从而 $g(\lambda, \nu) \leqslant p^*$ 成立.

拉格朗日对偶问题

拉格朗日对偶问题:

$$\max_{\lambda\geq 0,\nu} \; g(\lambda,\nu) = \max_{\lambda\geq 0,\nu} \inf_{x\in\mathbb{R}^n} \; L(x,\lambda,\nu)$$

弱对偶原理(Weak Duality)
$d^* \leqslant p^*$

- 称λ 和ν 为对偶变量, 设最优值为 d^*
- d^* 为p^* 的最优下界, 称 $p^* - d^*$ 为对偶间隙
- 拉格朗日对偶问题是一个凸优化问题
- $\mathrm{dom} g = \{(\lambda,\nu) \mid \lambda \geq 0, g(\lambda,\nu) > -\infty\}$, 称其元素为对偶可行解

由于对偶函数 $g(\boldsymbol{\lambda},\boldsymbol{\mu})$是凹函数, $\boldsymbol{\lambda} \in \mathbf{R}_+^m, \boldsymbol{\nu} \in \mathbf{R}^p$是凸集, 因此对偶问题是凸优化问题(凹函数在凸集上求最大), 其局部最优解就是全局最优解.

弱对偶性与强对偶性

弱对偶性: $d^* \leq p^*$

- 对凸问题与非凸问题都成立
- 可导出复杂问题的非平凡下界

强对偶性: $d^* = p^*$

- 对一般问题而言通常不成立
- (通常) 对凸问题成立
- 称保证凸问题强对偶性成立的条件为**约束品性**

凸优化问题**通常**能满足约束品性。

首先给出集合$\mathcal{D}$ 的相对内点集relint$\mathcal{D}$ 的定义.给定集合$\mathcal{D}$, 记其仿射包为

$$\textbf{affine}\,\mathcal{D} = \{x \mid x = \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_k x_k,\ x_1, x_2, \cdots, x_k \in \mathcal{D},\ \sum_{i=1}^{k} \theta_i = 1\}.$$

定义 (相对内点)

集合$\mathcal{D}$ 的相对内点集定义为

$$\text{relint}\mathcal{D} = \{x \in \mathcal{D} \mid \exists\, r > 0,\ \text{使得}\ B(x, r) \cap \textbf{affine}\,\mathcal{D} \subseteq \mathcal{D}\}.$$

$\mathrm{B}(\boldsymbol{x}, r) = \{\boldsymbol{y} \mid \| \boldsymbol{y} - \boldsymbol{x} \| < r\}$是半径为 r 、中心为 $\boldsymbol{x}$ 并由某种范数定义的球。

相对内点是内点的推广, 若$\mathcal{D}$ 本身的“维数”较低, 则$\mathcal{D}$ 不可能有内点, 但如果在它的仿射包**affine** $\mathcal{D}$ 中考虑, 则$\mathcal{D}$ 可能有相对内点.

集合 C 的仿射包的维数称为集合 C 的**仿射维数**。仿射维数与经典维数的定义不一致。例如, $\mathbf{R}^2$ 上的单位圆环 $\{\boldsymbol{x} \in \mathbf{R}^2 \mid \boldsymbol{x}_1^2 + \boldsymbol{x}_2^2 = 1\}$ 的仿射包是全空间 $\mathbf{R}^2$, 所以其仿射维数为 2 。但在其他大多数维数的定义下, $\mathbf{R}^2$ 上的单位圆环的维数为 1 。

如果集合 $C \subseteq \mathbf{R}^n$ 的仿射维数小于 n, 那么这个集合的仿射包 $\operatorname{aff} C \neq \mathbf{R}^n$ 。

例

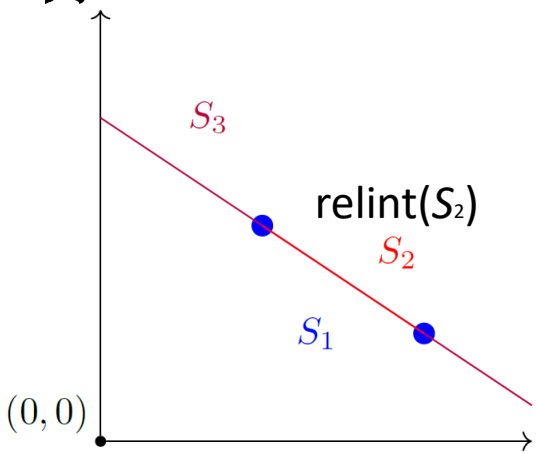

$S_1 = \{(1.5, 2), (3,1)\}$

$S_2 = \mathrm{conv}(S_1) = \{\theta(1.5,2) + (1-\theta)(3,1) \mid \theta \in [0,1]\}$

$S_3 = \mathrm{aff}(S_1) = \mathrm{aff}(S_2) = \{\theta(1.5,2) + (1-\theta)(3,1) \mid \theta \in \mathbb{R}\}$

$\mathrm{int}(S_2) =$ 空集

$\mathrm{relint}(S_2) = S_2 \backslash S_1$

$\mathrm{relint}(S_3) = S_3$

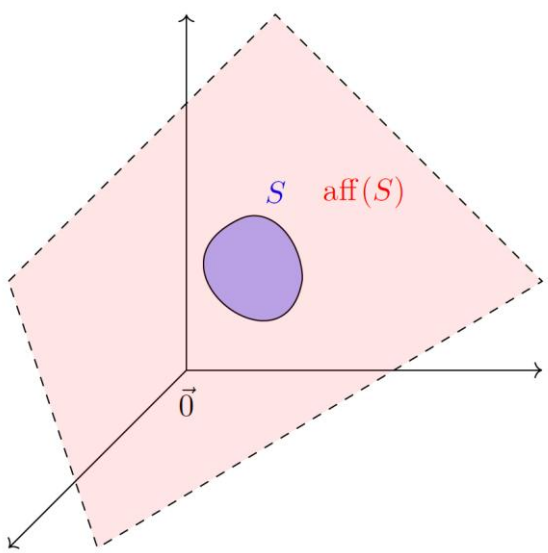

定义 (Slater约束品性)

若对凸优化问题

$$\min_{x\in\mathcal{D}} \quad f(x),\ \textbf{s.t.}\ c_i(x) \leqslant 0,\ i=1,2,\cdots,m, \quad Ax=b,$$

存在$x \in \mathrm{relint}\mathcal{D}$ 满足

$$c_i(x) < 0, \quad i=1,2,\cdots,m, \quad Ax=b,$$

则称对此问题Slater 约束品性满足.该约束品性也称为 Slater **条件**.

- Slater约束品性实际上是要求自然定义域$\mathcal{D}$ 的相对内点中存在使得不等式约束严格成立的点, **affine** $\mathcal{D}=\mathbb{R}^n$ 时相对内点就是内点.
- 不等式约束是仿射函数时, Slater条件可以放宽.设前k 个不等式约束是仿射的, 此时Slater约束品性变为:存在$x \in \mathrm{relint}\mathcal{D}$, 满足

  $$c_i(x) \le 0,\ i=1,2,\cdots,k; \quad c_i(x) < 0,\ i=k+1,k+2\cdots,m; \quad Ax=b,$$

  即对线性不等式约束无需要求其存在严格可行点.

集合 $\mathcal{D}$ 表示自变量 x 的自然定义域, 即 $\mathcal{D}=\mathrm{dom}\, f=\{x \mid f(x)<+\infty\}$.

可行域 $\mathcal{X}=\{x\in\mathcal{D}: c_i(x)\leqslant 0, i=1,2,\cdots,m; Ax=b\}$.

例 $\Omega = \{(x, y) \in \mathbb{R}^2 : -5 \le x \le 5, \frac{25}{4} \ge y \ge \frac{1}{4}x^2\}$,

蓝色点是满足Slater条件的可行点。

红色点是不满足Slater条件的可行点。

棕色点是不可行点。

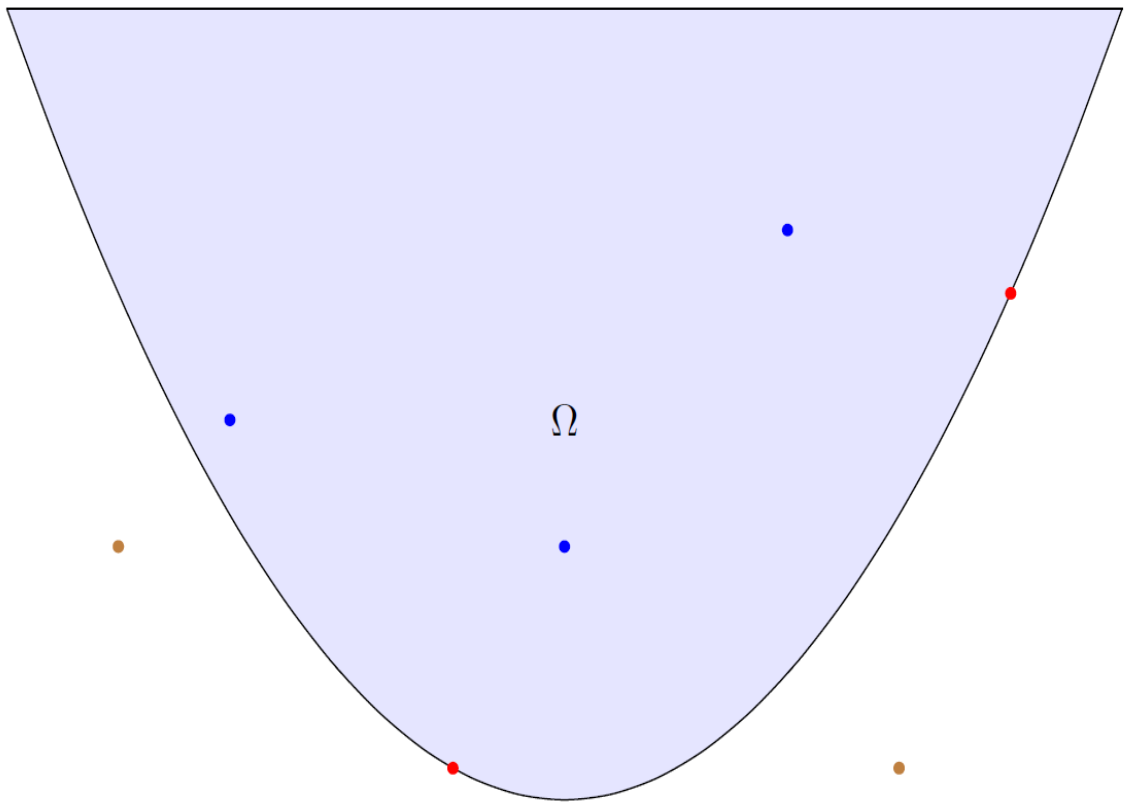

Slater约束品性与强对偶原理

定理

若凸优化问题满足*Slater*条件，则强对偶原理成立.

- 这里假设集合$\mathcal{D}$ 内部非空(即$\mathrm{relint}\mathcal{D} = \mathbf{int}\,\mathcal{D}$)，A 行满秩(否则可以去掉多余的线性等式约束)以及原始问题最优函数值p^* 有限.
- 需证明的结论：当$d^* > -\infty$ 时，对偶问题的最优解可以取到，即存在对偶可行解(λ^*, ν^*)，满足$g(\lambda^*, \nu^*) = d^* = p^*$.
- 定义集合

$$\begin{aligned}\mathbb{A} = \{(u, v, t) \mid \exists x \in \mathcal{D},\ c_i(x) \le u_i,\ i = 1, 2, \cdots, m,\\ Ax - b = v, f(x) \le t\}.\\ \mathbb{B} = \{(0, 0, s) \in \mathbb{R}^m \times \mathbb{R}^p \times \mathbb{R} \mid s < p^*\}.\end{aligned}$$

- 可以证明集合$\mathbb{A}$ 和$\mathbb{B}$ 是不相交的.

  假设$(u, v, t) \in \mathbb{A} \cap \mathbb{B}$.根据$(u, v, t) \in \mathbb{B}$，有$u = 0, v = 0$ 和$t < p^*$.

  由$(u, v, t) \in \mathbb{A}$，可知$f(x) \le t < p^*$，这与p^* 是原始问题最优值矛盾.

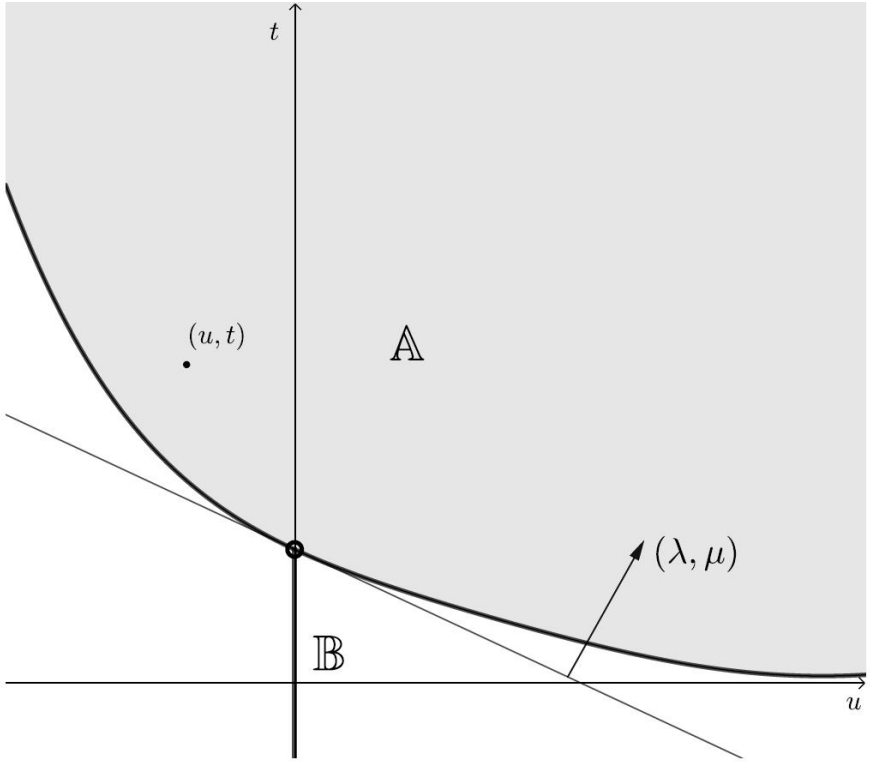

Figure: 集合$\mathbb{A}$ 和$\mathbb{B}$ 在u - t 方向投影的示意图
($\mathbb{A}$ 一般为有内点的凸集, $\mathbb{B}$ 是一条射线且不含点$(0,0,p^*)$)

因为$\mathbb{A}$ 和$\mathbb{B}$ 均为凸集, 由超平面分离定理, 存在$(\lambda,\nu,\mu)\neq 0$ 和α, 使得

$$\lambda^{\mathrm{T}}u+\nu^{\mathrm{T}}v+\mu t\geq\alpha,\quad\forall\,(u,v,t)\in\mathbb{A},$$
$$\lambda^{\mathrm{T}}u+\nu^{\mathrm{T}}v+\mu t\leq\alpha,\quad\forall\,(u,v,t)\in\mathbb{B}.$$

- 我们断言$\lambda \geq 0$ 和$\mu \geq 0$ (否则可以取u_i 和t 为任意大的正实数以及$\nu = 0$, 这会导致$\lambda^{\mathrm{T}} u + \mu t$ 在集合$\mathbb{A}$ 上无下界).
- 同时, 由于$\mu t \leq \alpha$ 对于所有$t < p^*$ 成立, 可得$\mu p^* \leq \alpha$.
- 对任意$x \in \mathcal{D}$, 取$(u, v, t) = (c_i(x), Ax - b, f(x)) \in \mathbb{A}$, 可知

$$\sum_{i=1}^{m} \lambda_i c_i(x) + \nu^{\mathrm{T}}(Ax - b) + \mu f(x) \geq \alpha \geq \mu p^*.$$

- 假设$\mu > 0$, 则

$$L(x, \frac{\lambda}{\mu}, \frac{\nu}{\mu}) \geq p^*.$$

进一步地, 我们有$g(\frac{\lambda}{\mu}, \frac{\nu}{\mu}) \geq p^*$, 根据弱对偶性$g(\frac{\lambda}{\mu}, \frac{\nu}{\mu}) \leq p^*$ 自然成立.因此, 必有$g(\frac{\lambda}{\mu}, \frac{\nu}{\mu}) = p^*$ 成立.说明在此情况下强对偶性满足, 且对偶最优解可以达到.

- 考虑$\mu = 0$ 的情况, 可以从上面得到对于所有的$x \in \mathcal{D}$,

$$\sum_{i=1}^{m} \lambda_i c_i(x) + \nu^{\mathrm{T}}(Ax - b) \geq 0.$$

- 取满足Slater条件的点x_S, 有$\underline{Ax_S - b = 0}$ $\sum_{i=1}^{m} \lambda_i c_i(x_S) \geq 0$.
- 又$\underline{c_i(x_S) < 0}$ 和$\lambda_i \geq 0$, 我们得到$\lambda = 0$, 上式化为

$$\nu^{\mathrm{T}}(Ax - b) \geq 0, \quad \forall\, x \in \mathcal{D}.$$

- 根据$(\lambda, \nu, \mu) \neq 0$可知$\nu \neq 0$，结合$A$行满秩有$A^{\mathrm{T}}\nu \neq 0$. 因为$x_S \in \operatorname{int}\mathcal{D}$, $\nu^{\mathrm{T}}(Ax_S - b) = 0$, 则存在 $\boldsymbol{e}$ 使得 $\tilde{x} = x_S + \boldsymbol{e} \in \mathcal{D}$, $\nu^{\mathrm{T}}(A\tilde{x} - b) < 0$. 另一方面根据 $\tilde{x} \in \mathcal{D}$有 $\nu^{\mathrm{T}}(A\tilde{x} - b) \geqslant 0$, 矛盾, 故$\mu = 0$不成立.
- 综上所述, Slater条件能保证强对偶性.
- 在定理的证明中, Slater条件保证了$\mu \neq 0$.

例

$$\begin{aligned} \min_{x\in\mathbb{R}} \quad & 5x^2 \\ \text{s.t.} \quad & 3x \le 5. \end{aligned}$$

原问题的最优解显然是$x^* = 0$， p^*=0

这是凸优化问题，且满足Slater约束条件。

Lagrangian函数：$L(x,\lambda) = 5x^2 + \lambda(3x-5)$.

对偶函数：$g(\lambda) = \min_x L(x,\lambda) = \min_x \{5x^2 + \lambda(3x-5)\}$.

这是个无约束可微凸优化问题，

$$\nabla_x L(x,\lambda) = 10x + 3\lambda = 0\ , \quad x^\star = -\frac{3}{10}\lambda$$

$$g(\lambda) = L(x^\star,\lambda) = 5(x^\star)^2 + \lambda(3x^\star - 5) = -\frac{9}{20}\lambda^2 - 5\lambda$$

拉格朗日对偶问题：$d^\star = \max_{\lambda\in\mathbb{R}_+}\left(-\frac{9}{20}\lambda^2 - 5\lambda\right)$.

求解得到 $\lambda^\star = 0$ ， $d^\star = 0$. 对偶间隙=0

例 $\min_{x_1,x_2} f(x_1,x_2)=\frac{1}{2}(x_1^2+x_2^2)\quad s.t.\, x_1=1$

分别求解原问题及其对偶问题，计算对偶间隙。

原问题的最优解显然是 $(x_1,x_2)^*=(1,0)$， $p^*=\frac{1}{2}$

这是凸优化问题，且满足Slater约束条件。

$$L(x_1,x_2,\nu)=\frac{1}{2}(x_1^2+x_2^2)+\nu(x_1-1)$$

$$g(\nu)=\min_{x_1,x_2}\mathcal{L}(x_1,x_2,\nu)=\min_{x_1,x_2}\frac{1}{2}(x_1^2+x_2^2)+\nu(x_1-1)$$

$$\frac{\partial\mathcal{L}}{\partial\mathbf{x}}=\mathbf{0},\quad \begin{cases}x_1+\nu=0\\x_2=0\end{cases},\quad \begin{cases}x_1=-\nu\\x_2=0\end{cases},$$

$$g(\nu)=-\frac{1}{2}\nu^2-\nu$$

拉格朗日对偶问题 $\max_{\nu} g(\nu)=-\frac{1}{2}\nu^2-\nu\rightarrow\nu^*=-1\rightarrow\begin{cases}x_1^*=1\\x_2^*=0\end{cases}$

对偶间隙=0

例：欠定方程组的最小范数解(minimum-norm solution)

$$\begin{array}{ll} \text{minimize} & \| \boldsymbol{x} \|^2 \\ \text{subject to} & \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b} \end{array}$$

其中, $\boldsymbol{A} \in \mathbb{R}^{m\times n}, \boldsymbol{b} \in \mathbb{R}^m, m \leqslant n, \mathrm{rank}(\boldsymbol{A}) = m$

拉格朗日函数为: $L(\boldsymbol{x}, \boldsymbol{\nu}) = \boldsymbol{x}^T\boldsymbol{x} + \boldsymbol{\nu}^T(\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b})$

对偶函数$g(\boldsymbol{\nu}) = \min_{\boldsymbol{x}\in R^n} L(\boldsymbol{x}, \boldsymbol{\nu})$, 这里 $L(\boldsymbol{x}, \boldsymbol{\nu})$ 是 $\boldsymbol{x}$ 的二次凸函数, 于是

$$\nabla_x L(\boldsymbol{x}, \boldsymbol{\nu}) = 2\boldsymbol{x} + \boldsymbol{A}^T\boldsymbol{\nu} = ,\quad \boldsymbol{x}^* = -\frac{1}{2}\boldsymbol{A}^T\boldsymbol{\nu}$$

将 $\boldsymbol{x}^*$ 代入 $L(\boldsymbol{x}, \boldsymbol{\nu})$ 中, 可得对偶函数:$g(\boldsymbol{\nu}) = -\frac{1}{4}\boldsymbol{\nu}^T\boldsymbol{A}\boldsymbol{A}^T\boldsymbol{\nu} - \boldsymbol{b}^T\boldsymbol{\nu}$

对偶问题为$\max_{\boldsymbol{\nu}} \{g(\boldsymbol{\nu}) = -\frac{1}{4}\boldsymbol{\nu}^T\boldsymbol{A}\boldsymbol{A}^T\boldsymbol{\nu} - \boldsymbol{b}^T\boldsymbol{\nu}\}$等价于$\min_{\boldsymbol{\nu}}\{\frac{1}{4}\boldsymbol{\nu}^T\boldsymbol{A}\boldsymbol{A}^T\boldsymbol{\nu} + \boldsymbol{b}^T\boldsymbol{\nu}\}$

这是个无约束凸优化问题。

$\nabla g(\boldsymbol{\nu}) = \frac{1}{2}\boldsymbol{A}\boldsymbol{A}^T\boldsymbol{\nu} + \boldsymbol{b} = 0,\quad \boldsymbol{\nu}^* = -2(\boldsymbol{A}\boldsymbol{A}^T)^{-1}\boldsymbol{b}$

原问题是凸的，约束是仿射的，只要存在一个可行点满足$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，Slater条件就成立，强对偶成立，得到 $\boldsymbol{x}^* = -\frac{1}{2}\boldsymbol{A}^T\boldsymbol{\nu}^* = \boldsymbol{A}^T(\boldsymbol{A}\boldsymbol{A}^T)^{-1}\boldsymbol{b}$

线性规划的对偶

线性规划如果有可行点，则满足Slater条件，强对偶成立。

标准形式

$$\begin{aligned} \min_{x} \quad & c^{\mathrm{T}}x \\ \text{s.t.} \quad & Ax = b \\ & x \geq 0 \end{aligned}$$

- 拉格朗日函数:

$$L(x,s,\nu) = c^{\mathrm{T}}x + \nu^{\mathrm{T}}(Ax-b) - s^{\mathrm{T}}x = -b^{\mathrm{T}}\nu + (A^{\mathrm{T}}\nu - s + c)^{\mathrm{T}}x$$

- 对偶函数:

$$g(s,\nu) = \inf_{x} \; L(x,s,\nu) = \begin{cases} -b^{\mathrm{T}}\nu, & A^{\mathrm{T}}\nu - s + c = 0 \\ -\infty, & \text{其他} \end{cases}$$

- 对偶问题:

$$\begin{aligned} \max_{s,\nu} \quad & -b^{\mathrm{T}}\nu, \\ \text{s.t.} \quad & A^{\mathrm{T}}\nu - s + c = 0, \\ & s \geq 0. \end{aligned} \quad \overset{y=-\nu}{\Longleftrightarrow} \quad \begin{aligned} \max_{s,y} \quad & b^{\mathrm{T}}y, \\ \text{s.t.} \quad & A^{\mathrm{T}}y + s = c, \\ & s \geq 0. \end{aligned}$$

线性规划的对偶：保留简单约束推导

$$\begin{aligned} \min_x \quad & c^{\mathrm{T}}x \\ \text{s.t.} \quad & Ax = b \\ & x \geq 0 \end{aligned}$$

- 若保留约束$x \geq 0$, 则拉格朗日函数为

$$L(x, y) = c^{\mathrm{T}}x - y^{\mathrm{T}}(Ax - b) = b^{\mathrm{T}}y + (c - A^{\mathrm{T}}y)^{\mathrm{T}}x.$$

- 对偶问题需要将$x \geq 0$ 添加到约束里：

$$\max_y \left\{ \inf_x \; b^{\mathrm{T}}y + (c - A^{\mathrm{T}}y)^{\mathrm{T}}x, \quad \text{s.t.} \;\; x \geq 0 \right\} \Rightarrow \begin{aligned} \max_y \quad & b^{\mathrm{T}}y, \\ \text{s.t.} \quad & A^{\mathrm{T}}y \leq c. \end{aligned}$$

此对偶问题可以通过将上页最后一个问题中的变量s 消去得到.

线性规划对偶问题的对偶

考虑对偶问题: $\max_y\ b^{\mathrm{T}}y$, s.t. $A^{\mathrm{T}}y \le c$

- 将$\max\ b^{\mathrm{T}}y$ 改写为$\min\ -b^{\mathrm{T}}y$, 对偶问题的拉格朗日函数为

$$L(y,x) = -b^{\mathrm{T}}y + x^{\mathrm{T}}(A^{\mathrm{T}}y - c) = -c^{\mathrm{T}}x + (Ax-b)^{\mathrm{T}}y.$$

- 因此得到对偶函数

$$g(x) = \inf_y\ L(y,x) = \begin{cases} -c^{\mathrm{T}}x, & Ax = b, \\ -\infty, & \text{其他}. \end{cases}$$

- 相应的对偶问题是

$$\begin{aligned} \max_x \quad & -c^{\mathrm{T}}x, \\ \text{s.t.} \quad & Ax = b, \\ & x \ge 0. \end{aligned}$$

与原始问题完全等价, 表明线性规划与其对偶问题互为对偶.

线性规划问题的对偶性

强对偶性: 若一个线性规划问题有最优解, 则其对偶问题有最优解, 且最优值相等.

dual \ primal	finite	unbounded	infeasible
finite	$\surd$	$\times$	$\times$
unbounded	$\times$	$\times$	$\surd$
infeasible	$\times$	$\surd$	$\surd$

- 若$p^* = -\infty$, 则$d^* \leq p^* = -\infty$, 因此对偶问题不可行
- 如果 $p^* = +\infty$, 那么原始问题无可行解. Slater 条件对原始问题不成立, 此时对偶问题既可能函数值无界 (对应 $d^* = +\infty$), 也可能无可行解 (对应 $d^* = -\infty$).

$$\begin{aligned} \min \quad & x_1 + 2x_2 \\ \text{s.t.} \quad & x_1 + x_2 = 1 \\ & 2x_1 + 2x_2 = 3 \end{aligned} \qquad \begin{aligned} \max \quad & p_1 + 3p_2 \\ \text{s.t.} \quad & p_1 + 2p_2 = 1 \\ & p_1 + 2p_2 = 2 \end{aligned}$$

例 生产问题模型

设某生产厂商生产两份产品A和B;

设一份产品A可以获利4单位价格，消耗2单位原料C、5单位原料D;

一份产品B可以获利3单位价格，消耗3单位原料C、2单位原料D。

现有24单位原料C，26单位原料D，问如何分配生产方式才能让获利最大。

这是一个线性规划问题，将其记作**问题 ($\boldsymbol{P}$)**，

$$
\begin{array}{ll}
\max & 4x_1 + 3x_2 \\
\text{s.t.} & 2x_1 + 3x_2 \leq 24 \\
 & 5x_1 + 2x_2 \leq 26 \\
 & x_1, x_2 \geq 0
\end{array}
$$

假如现在厂商不生产产品，而是要把原料都卖掉。设1单位原料C的价格为y_1，1单位原料D的价格为y_2，每种原料制定怎样的价格才合理呢?

一方面，产品A和B的价格反映了两种原料的使用价值，如果出售原料，那么不应该让原料的价格低于产出的产品价格，否则自己使用这些原料进行生产能获得更大的利润。于是，可以获得约束

$$\begin{aligned} 2y_1 + 5y_2 &\geq 4 \\ 3y_1 + 2y_2 &\geq 3 \end{aligned}$$

对卖方来说，只有满足该约束的报价才不亏。

在买方的角度，希望购得这批原料的钱越少越好。由于共有24单位原料C，26单位原料D，那么买方一共应该花费 $24y_1 + 26y_2$ 。合起来就得到了下面的线性规划问题，称为**问题 (D)**：

$$\begin{array}{ll} \min & 24y_1 + 26y_2 \\ \text{s.t.} & 2y_1 + 5y_2 \geq 4 \\ & 3y_1 + 2y_2 \geq 3 \\ & y_1, y_2 \geq 0 \end{array}$$

问题 (D) 就是问题 (P) 的对偶。

求解 (D) 得到的最优解 y_1 和 y_2 被称作 “影子价格 (shadow price) "，它代表了这些原材料的估计价值。

ℓ_1 正则化问题的对偶

$$\min_{x\in\mathbb{R}^n} \quad \frac{1}{2}\|Ax-b\|^2+\mu\|x\|_1$$

令$r=Ax-b$, 问题等价于$\min_{x\in\mathbb{R}^n}\frac{1}{2}\|r\|^2+\mu\|x\|_1$, s.t. $r=Ax-b$

- 拉格朗日函数:

$$\begin{aligned} L(x,r,\lambda) &= \frac{1}{2}\|r\|^2+\mu\|x\|_1-\langle\lambda, Ax-b-r\rangle \\ &= \frac{1}{2}\|r\|^2+\lambda^{\mathrm{T}}r+\mu\|x\|_1-(A^{\mathrm{T}}\lambda)^{\mathrm{T}}x+b^{\mathrm{T}}\lambda \end{aligned}$$

- 对偶函数:

$$g(\lambda)=\inf_{x,r} L(x,r,\lambda)=\begin{cases} b^{\mathrm{T}}\lambda-\frac{1}{2}\|\lambda\|^2, & \|A^{\mathrm{T}}\lambda\|_\infty\le\mu \\ -\infty, & \text{其他} \end{cases}$$

- 对偶问题:

$$\max \quad b^{\mathrm{T}}\lambda-\frac{1}{2}\|\lambda\|^2, \quad \text{s.t.} \quad \|A^{\mathrm{T}}\lambda\|_\infty\le\mu$$

例 去噪

$\mathbf{b} = \mathbf{x} + \mathbf{w}$　　$\mathbf{x} \in \mathbb{R}^n$是未知量，$\mathbf{b}$是观测量，$\mathbf{w}$是未知噪声

$\min \| \mathbf{x} - \mathbf{b} \|^2$　　最优解是$\mathbf{x}^* = \mathbf{b}$，没有意义。

```
import numpy as np
import numpy.linalg as la
import matplotlib.pyplot as plt
plt.style.use("default")
n=1000
x = np.zeros((n,))
x[0:250] = 1
x[250:500] = 3
x[750:1000] = 2
plt.plot(x,'.')
plt.axis([0, n, -1, 4])
plt.show()

u1=.5*np.sin(27*np.arange(1,n+1)**3)+.5
u2=.5*np.cos(13*np.arange(1,n+1)**3)+.5
a = 2 * np.pi
w=np.sqrt(-2*np.log(u1))*np.cos(a*u2)
y = x + 0.05 * w
plt.plot(y, '.')
plt.axis([0, n, -1, 4])
plt.show()
```

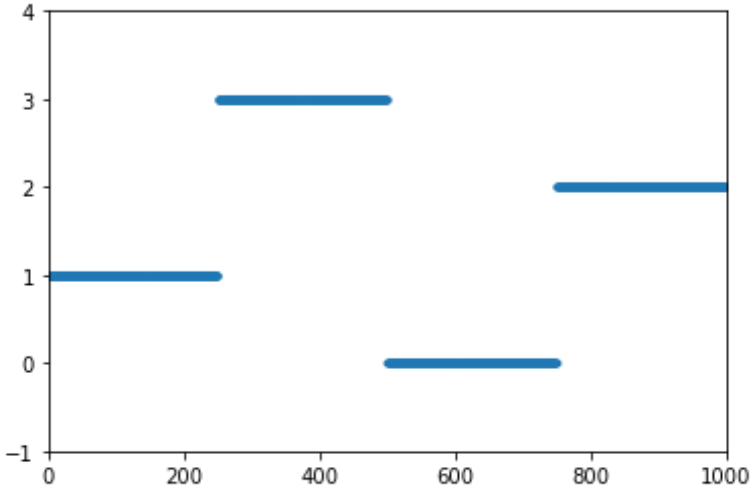

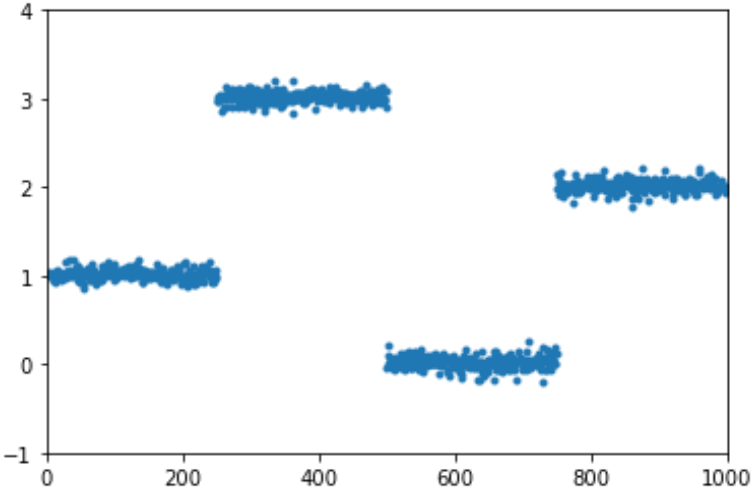

假设信号是光滑的，增加正则项 $R(\mathbf{x}) = \sum_{i=1}^{n-1}(x_i - x_{i+1})^2 = \| \mathbf{Lx} \|_2^2$

$$\mathbf{L} = \begin{pmatrix} 1 & -1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 1 & -1 & 0 & \cdots & 0 & 0 \\ 0 & 0 & 1 & -1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & 0 & 0 & & 1 & -1 \end{pmatrix} \in \mathbb{R}^{(n-1)\times n}$$

$$\min_{\mathbf{x}} \| \mathbf{x} - \mathbf{b} \|^2 + \lambda \| \mathbf{Lx} \|^2$$

最优解是 $\mathbf{x}_{\mathrm{RLS}}(\lambda) = \left(\mathbf{I} + \lambda \mathbf{L}^T \mathbf{L}\right)^{-1} \mathbf{b}$

```
I = np.eye(n)
LTL = L.T @ L
x_rls0 = la.solve(I + 0.1*LTL, y)
x_rls1 = la.solve(I + 1 * LTL, y)
x_rls2 = la.solve(I + 10 * LTL, y)
x_rls3 = la.solve(I + 100 * LTL, y)
```

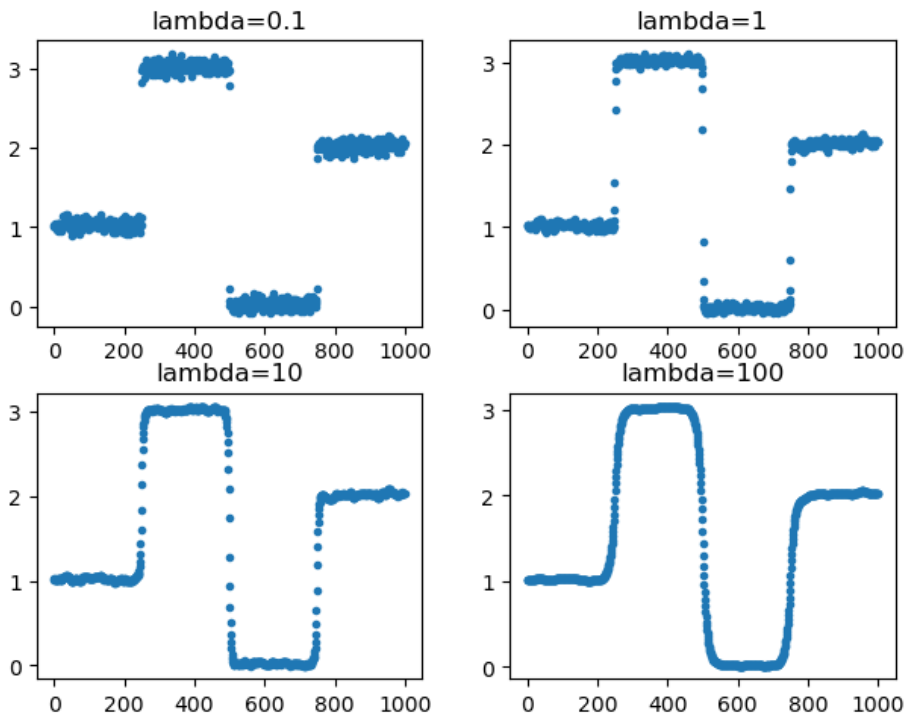

$\min \| \mathbf{x}-\mathbf{y} \|^2 + \lambda \| \mathbf{L}\mathbf{x} \|_1$

等价的优化问题 $\begin{array}{ll} \min\limits_{\mathbf{x},\mathbf{z}} & \| \mathbf{x}-\mathbf{y} \|^2 + \lambda \| \mathbf{z} \|_1 \\ \text{s.t.} & \mathbf{z} = \mathbf{L}\mathbf{x}. \end{array}$

Lagrangian 函数 $L(\mathbf{x},\mathbf{z},\mu) = \| \mathbf{x}-\mathbf{y} \|^2 + \lambda \| \mathbf{z} \|_1 + \boldsymbol{\mu}^T(\mathbf{L}\mathbf{x}-\mathbf{z})$

$$= \| \mathbf{x}-\mathbf{y} \|^2 + \left(\mathbf{L}^T\boldsymbol{\mu}\right)^T\mathbf{x} + \lambda \| \mathbf{z} \|_1 - \boldsymbol{\mu}^T\mathbf{z}. \quad \text{（可分离）}$$

$\min\limits_{\mathbf{x}} \| \mathbf{x}-\mathbf{y} \|^2 + \left(\mathbf{L}^T\boldsymbol{\mu}\right)^T\mathbf{x}$ 的最优解是$\mathbf{x} = \mathbf{y} - \frac{1}{2}\mathbf{L}^T\boldsymbol{\mu}$.

$$\min_{\mathbf{x}} \| \mathbf{x}-\mathbf{y} \|^2 + \left(\mathbf{L}^T\mu\right)^T\mathbf{x} = -\frac{1}{4}\boldsymbol{\mu}^T\mathbf{L}\mathbf{L}^T\boldsymbol{\mu} + \boldsymbol{\mu}^T\mathbf{L}\mathbf{y}.$$

$$\min_{\mathbf{z}} \lambda \| \mathbf{z} \|_1 - \boldsymbol{\mu}^T\mathbf{z} = \begin{cases} 0, & \| \boldsymbol{\mu} \|_\infty \le \lambda \\ -\infty, & \text{else.} \end{cases}$$

Lagrangian对偶函数 $q(\boldsymbol{\mu}) = \min\limits_{\mathbf{x},\mathbf{z}} L(\mathbf{x},\mathbf{z},\boldsymbol{\mu}) = \begin{cases} -\frac{1}{4}\mu^T\mathbf{L}\mathbf{L}^T\mu + \mu^T\mathbf{L}\mathbf{y}, & \| \mu \|_\infty \le \lambda, \\ -\infty, & \text{else.} \end{cases}$

对偶问题：$\begin{array}{ll} \max & -\frac{1}{4}\boldsymbol{\mu}^T\mathbf{L}\mathbf{L}^T\boldsymbol{\mu} + \boldsymbol{\mu}^T\mathbf{L}\mathbf{y} \\ \text{s.t.} & \| \boldsymbol{\mu} \|_\infty \le \lambda. \end{array}$

使用梯度投影法，步长取0.5

$$\boldsymbol{\mu}_{k+1} = P_C\left(\boldsymbol{\mu}_k - \frac{1}{4}\mathrm{LL}^T\boldsymbol{\mu}_k + \frac{1}{2}\mathrm{L}\mathbf{y}\right)$$

where $C = \{\mathbf{z} \in \mathbb{R}^{n-1}: -\lambda \le z_i \le \lambda, i = 1,2 \ldots, n-1\}$.
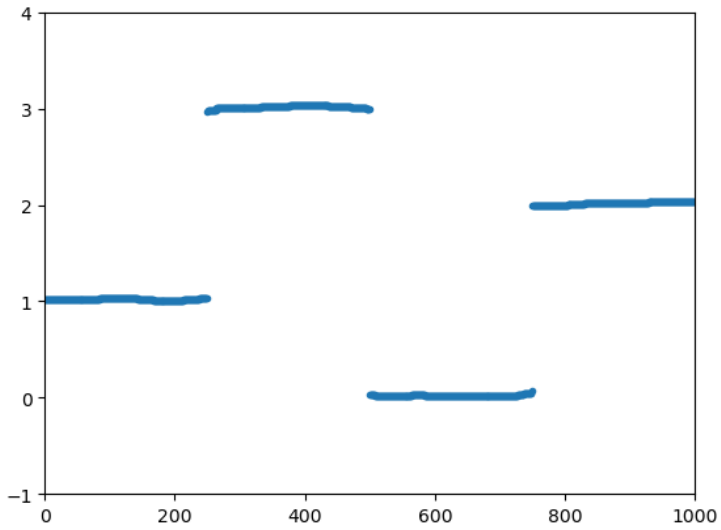
```
lam = 1.0
mu = np.zeros((n-1, ))
for i in range(1000):
    mu += -0.25 * L @ (L.T @ mu) + 0.5 * (L @ y)
    d = np.maximum(np.abs(mu), lam)
    mu = lam * mu / d
xde = y - 0.5 * L.T @ mu
plt.plot(xde, '.')
plt.axis([0, n, -1, 4])
plt.show()
```